

MAIA: Arquitectura de Referencia para Tutoría Inteligente Adaptativa en Educación Inclusiva Costarricense

Emmanuel Barrantes Vargas,
Isaac Francisco Moreno Fuentes

Resumen—Este paper propone el Marco de Aprendizaje Inclusivo y Adaptativo (MAIA), una arquitectura de referencia para sistemas tutores inteligentes orientados a las Aulas Integradas del MEP costarricense. El Décimo Informe Estado de la Educación (2025) documenta que menos del 35 % de los estudiantes en estos servicios alcanza la alfabetización y que el 41 % del profesorado reporta desgaste emocional significativo. El MAIA integra tres componentes técnicos: detección emocional multimodal en tiempo real mediante redes convolucionales y transformers de visión, clasificación cognitiva automatizada alineada con la Taxonomía de Bloom mediante BERT ajustado finamente, y un motor de adaptación por aprendizaje por refuerzo con control docente en el bucle (*human-in-the-loop*). Diseñado bajo restricciones de privacidad (Ley N° 8968) y hardware limitado, el sistema establece como indicadores objetivo una precisión de clasificación cognitiva ≥ 85 % y de detección afectiva ≥ 80 %, con operación autónoma en al menos el 70 % de las sesiones.

Index Terms—sistemas tutores inteligentes, computación afectiva, taxonomía de Bloom, aprendizaje por refuerzo, *human-in-the-loop*, educación inclusiva, Costa Rica

I. PROBLEMA E IMPORTANCIA

En el sistema educativo costarricense, la inclusión de estudiantes con discapacidad se gestiona mediante las Aulas Integradas y los Servicios de Apoyo Educativo. A pesar de que el Ministerio de Educación Pública (MEP) ha lanzado la “Guía Docente: IA en clase (2026)”, el Décimo Informe Estado de la Educación (2025) [1] advierte que el país atraviesa una “emergencia educativa” caracterizada por un grave rezago en competencias básicas y una incapacidad del sistema para personalizar el aprendizaje de manera efectiva.

El problema central es la desconexión entre el uso de herramientas de IA genéricas y la necesidad de una personalización profunda que considere el estado emocional del estudiante y la progresión cognitiva según la Taxonomía de Bloom, factores que el informe 2025 identifica como esenciales para superar la crisis de aprendizaje.

Este problema es crítico bajo la óptica del Estado de la Nación 2025:

Emmanuel Barrantes Vargas e Isaac Francisco Moreno Fuentes son estudiantes de la Maestría en Ciencia de la Computación, Tecnológico de Costa Rica.

- **Rezago Histórico:** El informe 2025 señala que la exclusión y el bajo rendimiento en estudiantes vulnerables han alcanzado niveles alarmantes. Según las pruebas PISA 2022, el estudiantado presenta niveles de comprensión lectora y razonamiento matemático equivalentes a primaria, con un retroceso de hasta diez años [1]. El desmantelamiento de programas de informática educativa como PRONIE-MEP-FOD agravó esta situación al dejar al sistema sin una política de acompañamiento tecnológico pedagógico.
- **Invisibilidad del Estudiante:** Existe una incapacidad técnica para diagnosticar y atender las brechas individuales en tiempo real, lo que el informe denomina “el apagón educativo” de la personalización [1].
- **Escalabilidad técnica:** La heterogeneidad de hardware entre instituciones del MEP exige una arquitectura que opere con recursos limitados y pueda desplegarse progresivamente, condición que los sistemas ITS genéricos existentes no satisfacen [1].

II. ANTECEDENTES

Esta sección organiza los antecedentes en cinco ejes: (A) los requisitos del dominio que delimitan el espacio de diseño del sistema; (B) el estado del arte en sistemas tutores inteligentes y aprendizaje adaptativo para estudiantes con discapacidad; (C) los avances en computación afectiva aplicados a entornos educativos; (D) la clasificación cognitiva automatizada mediante modelos de lenguaje alineados con la Taxonomía de Bloom; y (E) la brecha específica que esta investigación busca llenar.

II-A. Requisitos del Dominio

Las Aulas Integradas del MEP atienden a estudiantes con discapacidades heterogéneas dentro del sistema regular costarricense. Las estadísticas de educación especial del MEP [2] registran que menos del 35 % de los estudiantes en estos servicios alcanza la alfabetización, cifra que cuantifica la magnitud del problema de aprendizaje y establece la línea base que un sistema de IA debe ser capaz de medir y superar. Tres restricciones normativas y operativas condicionan directamente el diseño técnico de cualquier solución en este contexto.

Primero, la *Ley N° 8968 de Protección de Datos Personales* [3] impone requisitos de privacidad sobre el tratamiento de datos emocionales y cognitivos, restringiendo

las arquitecturas que deleguen procesamiento sensible en servicios de nube sin garantías de anonimización. Segundo, el *Décimo Informe Estado de la Educación 2025* [1] documenta un desgaste emocional significativo en el 41 % del profesorado, lo que implica que el sistema debe minimizar la carga administrativa sobre el docente de apoyo para ser operativamente viable. Tercero, la heterogeneidad de perfiles cognitivos y emocionales en las Aulas Integradas exige un motor de adaptación capaz de personalizar en tiempo real sin intervención manual continua. Estos tres factores —privacidad, carga docente y diversidad de perfiles— constituyen los requisitos funcionales y no funcionales que delimitan el espacio de diseño de la propuesta.

II-B. Sistemas Tutores Inteligentes y Aprendizaje Adaptativo

Los Sistemas Tutores Inteligentes (ITS, por sus siglas en inglés) constituyen la familia arquitectónica más consolidada para la personalización del aprendizaje mediado por computadora. Un ITS integra cuatro módulos funcionales: el *modelo del dominio* (representación del conocimiento a enseñar), el *modelo del estudiante* (estado cognitivo y afectivo inferido), el *módulo pedagógico* (estrategias de selección y secuenciación de contenido) y la *interfaz de interacción* [4]. La evolución de estos sistemas hacia arquitecturas de aprendizaje profundo y aprendizaje por refuerzo ha extendido su capacidad de adaptación a poblaciones con necesidades educativas especiales.

Ahmed et al. [4] proponen un marco de aprendizaje personalizado en tiempo real que emplea algoritmos de aprendizaje por refuerzo para ajustar dinámicamente el contenido, el ritmo y la dificultad de las lecciones según el estado emocional, el estilo de aprendizaje y el progreso cognitivo del estudiante. Su revisión abarca herramientas asistivas desde lectores de pantalla y reconocimiento de actividad humana hasta robots de apoyo para estudiantes con Trastorno del Espectro Autista (TEA), y sitúa la Taxonomía de Bloom como eje de monitoreo cognitivo continuo dentro del modelo del estudiante [4]. Complementariamente, Farhah et al. [5] examinan arquitecturas que integran IA generativa con componentes de accesibilidad y personalización: su análisis detalla cómo las señales de detección emocional y las estrategias conductuales adaptativas se incorporan al módulo pedagógico para ajustar el andamiaje cognitivo de forma individualizada [5].

Jadán-Guerrero et al. [6] sintetizan patrones de diseño verificados en educación especial y reportan que la incorporación de señales afectivas en tiempo real incrementa de manera consistente la personalización del contenido. Los autores también enfatizan el rol del docente como mediador indispensable de la interacción tecnológica, requisito que se traduce en exigencias concretas sobre la interfaz de explicabilidad del sistema [6]. Desde la perspectiva del perfilado del estudiante, Bhimavarapu [7] implementa una red neuronal artificial bicapa (*Bi-Stacked ANN*) que produce recomendaciones individualizadas a partir de características demográficas, académicas y de autopercepción de

la discapacidad; la selección de características mediante optimización por enjambre de partículas (PSO) ofrece un enfoque replicable para construir el modelo del estudiante en contextos con datos escasos [7].

Una limitación estructural de los enfoques previos en el contexto costarricense es que el modelo histórico de tecnología educativa se centró en la provisión de infraestructura y software genérico, sin incorporar mecanismos de adaptación dinámica ni modelos del estudiante [1]. Este modelo pasivo reproduce en el entorno digital las mismas restricciones de la instrucción presencial uniforme, subrayando la necesidad de una arquitectura ITS genuinamente adaptativa.

II-C. Computación Afectiva en Entornos de Aprendizaje

La computación afectiva estudia el diseño de sistemas capaces de detectar, interpretar y responder a los estados emocionales del usuario. En el contexto educativo, la integración de módulos afectivos en los ITS ha pasado de ser una extensión opcional a un componente funcional central, dado que el estado emocional del estudiante incide directamente sobre la carga cognitiva y la eficacia del aprendizaje.

Dutt y Ahuja [8] ofrecen evidencia empírica directa de esta relación: en un experimento con estudiantes con dificultades de aprendizaje interactuando con un ITS, midieron las emociones inducidas y la carga cognitiva durante la sesión. Sus resultados muestran que los estados emocionales positivos y la reducción de la carga cognitiva correlacionan con mejoras en la usabilidad y el compromiso del estudiante, validando que la adaptación emocional es un componente que afecta métricas de rendimiento medibles del sistema [8].

El sistema AISTY [9] ilustra una arquitectura concreta orientada a educación especial: combina estimación de atención y afecto basada en visión computacional con componentes de IA explicable (XAI) para adaptar el ritmo de interacción en niños con TEA. El módulo de visión monitorea señales faciales y de movimiento para inferir estados emocionales en tiempo real y ajustar tareas dinámicamente; simultáneamente, los mecanismos de XAI generan reportes interpretables para docentes y familias, abordando el problema de la caja negra que típicamente obstaculiza la adopción institucional de IA [9].

Técnicamente, los enfoques de detección emocional más empleados en ITS se agrupan en tres categorías: (i) basados en visión computacional, mediante análisis de expresiones faciales con redes convolucionales (CNN) o transformers de visión; (ii) basados en señales fisiológicas, como variabilidad del ritmo cardíaco o conductancia de la piel; y (iii) multimodales, que combinan varias fuentes para incrementar la robustez de la inferencia [4], [9]. En el contexto de las Aulas Integradas, la disponibilidad de hardware limita la viabilidad de las modalidades fisiológicas, orientando el diseño hacia enfoques de visión o multimodales de bajo costo de despliegue.

II-D. Clasificación Cognitiva Automatizada: NLP y Taxonomía de Bloom

La Taxonomía de Bloom [10] provee una jerarquía de seis niveles cognitivos —recordar, comprender, aplicar, analizar, evaluar y crear— que permite operacionalizar el progreso del estudiante en categorías discretas y accionables por algoritmos de adaptación. Al incorporarse como estructura de referencia en el modelo del estudiante de un ITS, la progresión cognitiva se convierte en una variable de estado discreta que el módulo pedagógico puede monitorear y utilizar para tomar decisiones de ajuste de contenido.

Das et al. [11] demostraron la viabilidad técnica de la clasificación automática de ítems de evaluación en los niveles de Bloom mediante dos enfoques de procesamiento del lenguaje natural: un clasificador LDA etiquetado y un clasificador de texto multiclase basado en BERT. Evaluados sobre un corpus de más de 3.000 ítems, estos modelos alcanzaron precisiones del 83 % y 89 % respectivamente [11]. Estos resultados sientan las bases técnicas para construir un componente de seguimiento cognitivo automatizado capaz de mapear las respuestas del estudiante a indicadores de logro curriculares sin intervención manual del docente.

En el plano de la generación de contenido, Barros et al. [12] documentan un estudio de investigación-acción en el que docentes emplearon *prompts* de IA generativa para diseñar lecciones secuenciadas según Bloom, obteniendo mayor compromiso cognitivo de orden superior [12]. Kwan et al. [13] examinan rediseños del aula invertida en los que la IA generativa produce actividades previas a la clase alineadas con Bloom y retroalimentación formativa automatizada durante la sesión presencial. El modelo de interacción estudiante-docente-IA que proponen ofrece un esquema de flujo de trabajo pedagógico aplicable a las Aulas Integradas, donde la automatización de tareas repetitivas de evaluación es una restricción crítica de diseño [13].

II-E. Brecha Identificada en la Literatura

La revisión de los antecedentes evidencia tres líneas de investigación activas —ITS adaptativos, computación afectiva y clasificación cognitiva con NLP— que han sido desarrolladas predominantemente de forma aislada o con integraciones parciales. Aunque Ahmed et al. [4] y Farhah et al. [5] señalan la necesidad de combinar múltiples componentes, ningún sistema documentado integra de forma cohesiva y validada: (i) un motor adaptativo basado en aprendizaje por refuerzo, (ii) un módulo de detección emocional en tiempo real, y (iii) un clasificador cognitivo NLP alineado con la Taxonomía de Bloom, todo ello bajo restricciones simultáneas de privacidad de datos, conectividad limitada y alta diversidad de perfiles propias de la educación especial en América Latina.

Bravo Condoy et al. [14] confirman que la preparación docente insuficiente y el acceso desigual a la tecnología son los obstáculos primarios para la adopción de IA

educativa en contextos comparables al costarricense, lo que subraya que las restricciones operativas del entorno deben incorporarse desde la fase de diseño arquitectónico y no tratarse como consideraciones de implementación tardía. La guía docente del MEP [15] y la Estrategia Nacional de IA [16] proporcionan el marco normativo disponible en el país, pero ninguno especifica protocolos técnicos para la personalización adaptativa en educación especial. Esta brecha —entre el marco normativo vigente y la arquitectura técnica requerida— define con precisión el problema de investigación que se aborda en las secciones siguientes.

III. PROPUESTA

Este trabajo propone el *Marco de Aprendizaje Inclusivo y Adaptativo* (MAIA), una arquitectura de referencia para sistemas tutores inteligentes orientados a las Aulas Integradas del MEP. El marco integra en un diseño cohesivo tres componentes técnicos que la literatura ha desarrollado de forma aislada: detección emocional multimodal, seguimiento cognitivo automatizado mediante procesamiento del lenguaje natural, y un motor de adaptación basado en aprendizaje por refuerzo con control docente en el bucle (*human-in-the-loop*).

III-A. Visión General de la Arquitectura

El MAIA se organiza en cuatro capas funcionales con responsabilidades claramente delimitadas (Fig. 1). La **capa de percepción** captura señales multimodales del estudiante (video, audio y registro de interacción). La **capa de análisis** procesa en paralelo el estado afectivo y el nivel cognitivo del estudiante a partir de esas señales. La **capa de decisión** combina ambos resultados para seleccionar la siguiente acción pedagógica, activando la intervención del docente únicamente cuando la decisión supera un umbral de impacto configurable. La **capa de presentación** entrega el contenido adaptado al estudiante y provee al docente de un tablero de supervisión con alertas.




Figura 1: Arquitectura de referencia del Marco de Aprendizaje Inclusivo y Adaptativo (MAIA). Las flechas indican el flujo de información entre capas.

Las cuatro capas de la figura describen el flujo de información a alto nivel; los módulos que se detallan a continuación son las unidades de implementación que realizan ese flujo. El **Módulo de Percepción Afectiva** abarca tanto la capa de percepción como la rama afectiva de la capa de análisis, ya que el procesamiento emocional es inseparable de la adquisición de la señal. El **Módulo de Seguimiento Cognitivo** corresponde a la rama cognitiva de la capa de análisis. El **Motor de Adaptación** implementa la capa de decisión, y la **Interfaz Docente** materializa la capa de presentación.

III-B. Módulo de Percepción Afectiva

El módulo de percepción afectiva captura y fusiona tres flujos de señales del estudiante para producir un vector de estado emocional $\mathbf{e} \in [0, 1]^n$ actualizado en tiempo real. La **rama visual** emplea una red convolucional (CNN) o un transformer de visión (ViT) que procesa los fotogramas de la cámara web y clasifica micro-expresiones faciales en categorías como frustración, aburrimiento, atención o entusiasmo. La **rama de audio** realiza análisis prosódico sobre la señal del micrófono —velocidad de habla, tono, duración de las pausas— para obtener una señal complementaria del estado emocional que no depende de la expresión facial. La **rama de interacción** extrae patrones implícitos del comportamiento del estudiante sobre la interfaz: latencia de respuesta, frecuencia de errores y velocidad de navegación entre pantallas.

Las tres ramas se combinan mediante *fusión tardía* (*late fusion*): cada rama produce su propia estimación de estado emocional de forma independiente, y un componente de fusión pondera y agrega los resultados. Esta estrategia permite que cada rama sea entrenada, actualizada o reemplazada de forma independiente sin afectar al resto del módulo, lo que resulta especialmente importante en un contexto de despliegue progresivo como el del MEP, donde la disponibilidad de hardware puede variar entre instituciones.

III-C. Módulo de Seguimiento Cognitivo

El módulo de seguimiento cognitivo evalúa el nivel de complejidad cognitiva de las interacciones del estudiante y lo mapea a uno de los seis niveles de la Taxonomía de Bloom: recordar, comprender, aplicar, analizar, evaluar y crear. La entrada del módulo son las respuestas textuales del estudiante —ya sea texto escrito o transcripción de audio— y su salida es un par (b, p) , donde $b \in \{1, \dots, 6\}$ es el nivel de Bloom inferido y $p \in [0, 1]$ es la confianza asociada.

El mecanismo de clasificación se basa en un modelo BERT ajustado finamente (*fine-tuned*) sobre un corpus de ítems de evaluación etiquetados con niveles de Bloom, siguiendo la metodología de Das et al. [11], que alcanzó un 89 % de precisión en clasificación multiclase. Para el contexto costarricense, el modelo se re-entrenaría sobre material curricular del MEP en español, alineando las categorías de Bloom con los indicadores de logro oficiales.

Cada respuesta del estudiante actualiza el modelo del estudiante en tiempo real: si p supera un umbral mínimo de confianza, b se registra en el historial cognitivo de la sesión; de lo contrario, el sistema solicita una actividad de clarificación antes de actualizar el estado.

III-D. Motor de Adaptación

El motor de adaptación toma como entrada el vector emocional $\mathbf{e}$, el nivel cognitivo b y el historial de la sesión, y produce la siguiente acción pedagógica a^* del espacio de acciones disponibles: avanzar al siguiente nivel de Bloom, reforzar el nivel actual con un ejercicio alternativo, cambiar la modalidad de presentación del contenido, o pausar y notificar al docente.

El motor combina una política inicial basada en reglas pedagógicas del MEP con un algoritmo de aprendizaje por refuerzo que refina dicha política con cada interacción. La política inicial codifica criterios curriculares concretos: no avanzar al siguiente nivel de Bloom si la confianza del clasificador es inferior a un umbral predefinido, o pausar la actividad si el vector emocional indica frustración sostenida durante más de k turnos consecutivos. Este mecanismo de arranque resuelve el problema de arranque en frío (*cold start*) del RL puro, que requeriría miles de interacciones antes de producir decisiones pedagógicamente coherentes.

III-E. Interfaz Docente (Human-in-the-Loop)

La interfaz docente opera como el mecanismo de control y supervisión del sistema. Recibe las decisiones del motor de adaptación que superan el umbral de impacto τ (configurable por institución) y las presenta al docente para su aprobación o ajuste. Los eventos que activan esta intervención son: un cambio de nivel cognitivo, una pausa prolongada de actividad, o la detección de un estado emocional crítico sostenido. Fuera de estos casos, el sistema opera de forma autónoma.

Adicionalmente, la interfaz provee un tablero de supervisión (*dashboard*) con el estado en tiempo real de cada estudiante: nivel cognitivo actual, vector emocional resumido, progreso en el currículo y alertas pendientes. Toda intervención del docente (aprobación, rechazo o ajuste de una decisión propuesta) se registra y retroalimenta al motor de adaptación como ejemplo etiquetado, lo que permite que la política de RL mejore progresivamente en función del criterio pedagógico específico de cada aula. Este ciclo de retroalimentación cierra el bucle entre la autonomía del sistema y el conocimiento experto del docente.

III-F. Restricciones de Diseño

El MAIA incorpora desde su fase arquitectónica las restricciones operativas identificadas en los antecedentes. La Tabla I mapea cada restricción a la decisión técnica que la satisface, de modo que el cumplimiento normativo y la viabilidad de despliegue sean propiedades de la arquitectura y no consideraciones de implementación tardía.

Cuadro I: Restricciones del dominio y decisiones técnicas del MAIA

Restricción	Origen	Decisión técnica
Privacidad de datos emocionales y cognitivos	Ley N° 8968	Procesamiento en el borde (<i>edge computing</i>); anonimización previa a cualquier transmisión externa
Hardware limitado en aulas	Presupuesto MEP	Percepción multimodal restringida a cámara y micrófono; sin sensores fisiológicos
Desgaste docente (41 %)	PEN 2025	Intervención docente activada únicamente cuando $\text{impacto} > \tau$
Diversidad de perfiles cognitivos	Aulas Integradas	Política inicial por reglas para garantizar coherencia pedagógica desde la primera interacción

IV. DISEÑO EXPERIMENTAL PROPUESTO

Dado que el Marco de Aprendizaje Inclusivo y Adaptativo (MAIA) constituye una arquitectura de referencia y no un sistema desplegado, su validación se plantea como un protocolo escalonado que progresa desde la evaluación aislada de cada módulo hasta la validación del sistema integrado en el aula. Esta gradación es coherente con el diseño desacoplado por fusión tardía descrito en la Propuesta, y permite distinguir con claridad qué propiedades pueden verificarse de forma temprana sobre datos etiquetados y cuáles requieren un despliegue real.

IV-A. Hipótesis de Validación

El desempeño esperado de MAIA se expresa mediante tres hipótesis falsables, una por cada módulo central de la arquitectura:

- **H1 (Seguimiento cognitivo).** El clasificador cognitivo, basado en un modelo BERT ajustado finamente, alcanza una precisión igual o superior al 85 % en los seis niveles de la Taxonomía de Bloom sobre un corpus curricular costarricense en español, tomando como referencia el 83 % y 89 % reportados por Das et al. [11] en inglés.
- **H2 (Percepción afectiva).** El módulo de percepción afectiva multimodal identifica los estados de frustración, aburrimiento y atención con una precisión igual o superior al 80 % y una latencia máxima de 200 ms por fotograma sobre el hardware objetivo, umbral dentro del cual la retroalimentación se percibe como continua [9].
- **H3 (Control docente).** El sistema opera de forma autónoma en al menos el 70 % de las sesiones, entendiendo por autonomía aquellas que concluyen sin superar el umbral de impacto configurable que activa la intervención del docente.

IV-B. Fase 1: Validación de Componentes

La primera fase evalúa cada módulo de manera aislada y sin participación de estudiantes, sobre conjuntos de datos

etiquetados, lo que permite iterar sobre los modelos sin riesgo ético. El módulo de seguimiento cognitivo se evalúa sobre un corpus de ítems del currículo del Ministerio de Educación Pública (MEP) anotados por nivel de Bloom; para garantizar la calidad de las etiquetas se propone una doble anotación por especialistas curriculares y la medición del acuerdo entre anotadores mediante el coeficiente kappa de Cohen [17]. El desempeño se cuantifica mediante la precisión global y la medida F1 promediada por clase (F1 macro), apropiada ante el desbalance esperado entre los seis niveles de Bloom, complementadas con la matriz de confusión para identificar confusiones sistemáticas entre niveles cognitivos adyacentes. Como línea base de comparación se emplean clasificadores clásicos de menor complejidad, replicando el enfoque de Das et al. [11]. El módulo de percepción afectiva se valida sobre un repositorio público de expresiones faciales en contexto educativo, tomando como línea base una configuración basada únicamente en visión que se contrasta con la configuración multimodal completa, de modo que se justifique empíricamente la estrategia de fusión tardía. Para este módulo se reportan la precisión y la medida F1 de cada estado afectivo, junto con la latencia de inferencia por fotograma —expresada en percentiles, mediana y percentil 95— sobre el hardware objetivo, con el fin de verificar el umbral de 200 ms establecido en la hipótesis H2. En ambos módulos las particiones de entrenamiento y prueba se separan por estudiante para evitar fugas de identidad.

IV-C. Fase 2: Validación de Integración

La segunda fase examina el sistema completo en sesiones controladas, con el objetivo de medir la latencia de extremo a extremo, la proporción de sesiones autónomas (hipótesis H3), el número de intervenciones docentes por sesión y la recompensa acumulada del agente de refuerzo como indicador de la estabilidad del bucle de adaptación con control docente. La línea base de esta fase es la comparación entre el motor de adaptación operando como aprendizaje por refuerzo puro frente al motor inicializado con la política de reglas pedagógicas del MEP, con el fin de evidenciar que dicha política mitiga el problema de arranque en frío descrito en la Propuesta.

IV-D. Fase 3: Estudio Ecológico en Aulas Integradas

La fase final consiste en un cuasi-experimento en aulas reales que contrasta el uso de MAIA frente a una condición de instrucción no adaptativa. Las variables dependientes incluyen los indicadores de logro curricular, el compromiso del estudiante, la carga de trabajo percibida por el docente —medida con el Índice de Carga de Tarea de la NASA (NASA Task Load Index, NASA-TLX) [18]— y la usabilidad del sistema —evaluada con la Escala de Usabilidad del Sistema (System Usability Scale, SUS) [19]. Dado que el tamaño de muestra esperado en este contexto es reducido, el análisis estadístico privilegia pruebas no paramétricas y el reporte del tamaño del efecto por encima de la mera significancia estadística.

IV-E. Consideraciones Éticas y Amenazas a la Validez

Por involucrar la participación de seres humanos en la investigación, y de manera especialmente sensible por tratarse de una población vulnerable, el protocolo requiere aprobación de un comité de ética, consentimiento informado de los responsables y asentimiento de los estudiantes, y el procesamiento de datos sensibles en el borde (*edge computing*) conforme a la Ley N° 8968. Entre las principales amenazas a la validez se anticipan el efecto de novedad, el sesgo del docente al aprobar o rechazar decisiones —que retroalimenta directamente al motor de adaptación—, el posible sesgo del modelo afectivo entre estudiantes con distintos perfiles de expresividad, y la limitada generalización derivada de la heterogeneidad de hardware entre instituciones.

DECLARACIÓN DE TRANSPARENCIA Y USO ÉTICO DE IA

Para la realización de este documento, se utilizaron las herramientas de IA NotebookLM, SciSpace, Claude y Perplexity como un medio auxiliar para apoyar y acelerar el desarrollo del mismo, siguiendo los lineamientos éticos de la Unidad de Posgrado del TEC [20]. Específicamente, NotebookLM y SciSpace se emplearon para la síntesis de información disponible, y tanto Claude como Perplexity se utilizaron para el formato, revisión ortográfica y de redacción de este documento.

REFERENCIAS

- [1] Programa Estado de la Nación, *Décimo Informe Estado de la Educación 2025*. San José, Costa Rica: CONARE-PEN, 2025, accedido: 17 de marzo de 2026. [Online]. Available: <https://repositorio.conare.ac.cr/items/762885cb-93f7-4b5a-8ca6-cdcc2ca8e5df>
- [2] Ministerio de Educación Pública de Costa Rica, “Servicios de educación especial 2014–2021,” Departamento de Análisis Estadístico, MEP, San José, Costa Rica, Tech. Rep., 2022. [Online]. Available: <https://www.mep.go.cr/sites/default/files/2024-05/serviciosdeeducacionespecial-2014-2021.pdf>
- [3] Asamblea Legislativa de Costa Rica, “Ley n° 8968: Protección de la persona frente al tratamiento de sus datos personales,” Sistema Costarricense de Información Jurídica, 2011. [Online]. Available: https://pgrweb.go.cr/scij/Busqueda/Normativa/Normas/nrm_texto_completo.aspx?param1=NRTC&nValor1=1&nValor2=70975&nValor3=85989&strTipM=TC
- [4] S. Ahmed, M. S. Rahman, M. S. Kaiser, and A. S. M. S. Hosen, “Advancing personalized and inclusive education for students with disability through artificial intelligence: Perspectives, challenges, and opportunities,” *Digital*, vol. 5, no. 2, p. 11, 2025.
- [5] N. Farhah, A. Wadood, A. A. Alqarni, M. I. Uddin, and T. H. H. Aldhyani, “Enhancing adaptive learning with generative AI for tailored educational support for students with disabilities,” *Journal of Disability Research*, 2025.
- [6] J. Jadán-Guerrero, K. Tamayo-Narvaez, E. Méndez, and M. Valenzuela, “Adaptive learning environments: Integrating artificial intelligence for special education advances,” in *Communications in Computer and Information Science*. Springer, 2024.
- [7] U. Bhimavarapu, “Empowering students with disabilities in education through AI-driven approaches,” in *Advances in Educational Technologies and Instructional Design*. IGI Global, 2025.
- [8] S. Dutt and N. J. Ahuja, “Intelligent tutoring effects on induced emotions and cognitive load of learning-disabled learners,” *Disability and Rehabilitation: Assistive Technology*, 2024.
- [9] A. S. M. Jaya and M. H. F. M. Fauadi, “AISTY: An explainable AI-driven vision-based adaptive learning system for children with autism spectrum disorder,” *International Journal of Research and Innovation in Social Science*, 2024. [Online]. Available: <https://repository.gyaanarth.com/ijriss/9/10/aisty-an-explainable-ai-driven-vision-based-adaptive-learning-system-for-children-with-autism-spectrum-disorder-1663>
- [10] B. S. Bloom, *Taxonomy of Educational Objectives: The Classification of Educational Goals. Handbook I: Cognitive Domain*. New York: David McKay Company, Inc., 1956.
- [11] S. Das, S. K. Das Mandal, and A. Basu, “Identification of cognitive learning complexity of assessment questions using multi-class text classification,” *Contemporary Educational Technology*, 2020.
- [12] J. B. S. Barros, M. Goldmeyer, and F. Lovemberger, “Taxonomia de Bloom e IA na educação: do pensamento cognitivo à construção criativa do conhecimento,” *Anais do IV ENLICSUL*, 2025.
- [13] P. Kwan, R. Kadel, T. D. Memon, and S. S. Hashmi, “Reimagining flipped learning via Bloom’s taxonomy and student–teacher–GenAI interactions,” *Education Sciences*, 2025.
- [14] E. F. Bravo Condoy, R. O. Bravo Loaiza, M. K. Rivera Gárate, and C. J. Cavezas Fernández, “Inteligencia artificial y tecnologías emergentes en el aprendizaje personalizado,” *Preprint*, 2025.
- [15] Ministerio de Educación Pública de Costa Rica, *Inteligencia Artificial en clase: Guía para docentes*, MEP, UNESCO, Naciones Unidas, ULACIT, San José, Costa Rica, 2026, accedido: 17 de marzo de 2026. [Online]. Available: <https://www.mep.go.cr/sites/default/files/2026-02/GuiaDocenteIA.pdf>
- [16] Ministerio de Ciencia, Innovación, Tecnología y Telecomunicaciones (MICITT), “Estrategia nacional de inteligencia artificial de costa rica 2024–2027,” MICITT, San José, Costa Rica, Tech. Rep., 2024. [Online]. Available: <https://www.micitt.go.cr/sites/default/files/2024-10/Estrategia%20Nacional%20de%20Inteligencia%20Artificial%20de%20Costa%20Rica%20ESP.pdf>
- [17] J. Cohen, “A coefficient of agreement for nominal scales,” *Educational and Psychological Measurement*, vol. 20, no. 1, pp. 37–46, 1960.
- [18] S. G. Hart and L. E. Staveland, “Development of NASA-TLX (task load index): Results of empirical and theoretical research,” in *Human Mental Workload*, ser. Advances in Psychology, P. A. Hancock and N. Meshkati, Eds. North-Holland, 1988, vol. 52, pp. 139–183.
- [19] J. Brooke, “SUS: A ‘quick and dirty’ usability scale,” in *Usability Evaluation in Industry*, P. W. Jordan, B. Thomas, B. A. Weerdmeester, and I. L. McClelland, Eds. London: Taylor & Francis, 1996, pp. 189–194.
- [20] M. A. Herrera, S. C. Ramírez, and H. E. Vargas, “Políticas de uso de la IA para trabajos académicos de investigación,” Unidad de Posgrado de la Escuela de Ingeniería en Computación, Tecnológico de Costa Rica, Lineamientos éticos, feb 2025, propuesto el 3 de febrero de 2025.