

Introducción a la Investigación

Tarea 2: Tesis de Maestría

Emmanuel Barrantes Vargas
Isaac Francisco Moreno Fuentes

Tecnológico de Costa Rica
Maestría en Ciencias de la Computación

Resumen—
Index Terms—

I. TESIS 1

I-A. Título

Exploring Emotion Recognition of Students in Virtual Reality Classrooms Through Convolutional Neural Networks and Transfer Learning Techniques (Explorando el reconocimiento de emociones de los estudiantes en aulas de realidad virtual a través de redes neuronales convolucionales y técnicas de aprendizaje por transferencia).

I-B. Autor

Michael Shomoye.

I-C. Resumen

“En los entornos educativos contemporáneos, comprender y evaluar el compromiso de los estudiantes a través de señales no verbales, especialmente las expresiones faciales, es fundamental. Tales señales han informado durante mucho tiempo a los educadores sobre los estados cognitivos y emocionales de los estudiantes, ayudándoles a adaptar sus métodos de enseñanza. Sin embargo, el auge de las plataformas de aprendizaje en línea y las tecnologías avanzadas como la Realidad Virtual (RV) desafían los modos convencionales de medir el compromiso de los estudiantes, especialmente cuando ciertas características faciales se oscurecen o están completamente ausentes. Este trabajo explora el potencial de las Redes Neuronales Convolucionales (CNN), específicamente un modelo de enfoque de entrenamiento personalizado adaptado de la arquitectura ResNet50, para reconocer y distinguir expresiones faciales sutiles en tiempo real, como la neutralidad, el aburrimiento, la felicidad y la confusión. La novedad del enfoque es doble: primero, se optimiza el poder de las CNN para analizar las expresiones faciales en plataformas de aprendizaje digital. Segundo, se innova para el contexto de la RV centrándose en la mitad inferior del rostro para abordar los desafíos de oclusión que plantea el uso de visores de RV. A través de una experimentación exhaustiva, se compara el rendimiento del modelo con la red neuronal residual 50 predeterminada (ResNet50) y se evalúa frente a conjuntos de datos de rostro completo y de rostro ocluido por RV. En última instancia, este esfuerzo tiene como objetivo proporcionar a los educadores

una herramienta sofisticada para la evaluación en tiempo real del compromiso de los estudiantes en entornos de aprendizaje tecnológicamente avanzados, enriqueciendo la experiencia de enseñanza y aprendizaje.”

I-D. Problema que busca resolver

La tesis busca resolver la dificultad que enfrentan los educadores para evaluar el compromiso y el estado emocional de los estudiantes en entornos de aprendizaje virtuales y de Realidad Virtual. En un aula física, los profesores dependen de señales no verbales y expresiones faciales para ajustar su enseñanza, pero en entornos de RV, los visores ocultan la parte superior del rostro (oclusión), eliminando pistas visuales críticas y creando una desconexión entre la instrucción y las necesidades del estudiante.

I-E. Objetivos

Objetivo General: Desarrollar un modelo de reconocimiento de emociones técnicamente robusto, pedagógicamente valioso y éticamente responsable que permita a los educadores obtener información sobre el compromiso de los estudiantes en tiempo real dentro de aulas de RV.

Objetivos Específicos:

1. Comparar el rendimiento de la arquitectura ResNet50 con otros modelos de CNN prominentes como VGG19 y MobileNet en el contexto específico de reconocimiento facial en aulas de RV.
2. Evaluar la eficacia de un modelo personalizado basado en ResNet50 para diferenciar expresiones sutiles como neutralidad, aburrimiento, felicidad y confusión.
3. Determinar las técnicas de preprocesamiento óptimas (como el uso de imágenes en escala de grises) para mejorar el reconocimiento de emociones.
4. Superar el desafío de la oclusión facial causada por los visores de RV enfocándose en la parte inferior del rostro.

I-F. Hipótesis

La hipótesis no se encuentra explícitamente en el texto pero se infiere que un modelo de Red Neuronal Convolucional (basado en ResNet50) que utilice aprendizaje por transferencia y se centre en las características de la mitad inferior del rostro podría superar las limitaciones de oclusión de los visores de

RV y clasificar con precisión estados emocionales clave del estudiante. Los resultados comprobaron esta hipótesis: el modelo personalizado no solo superó a la versión predeterminada de ResNet50 y a otros modelos, sino que también demostró una alta capacidad para distinguir el aburrimiento de la neutralidad tanto en rostros completos como ocluidos.

I-G. Resumen de la metodología empleada

La investigación empleó un enfoque de aprendizaje supervisado y aprendizaje por transferencia utilizando la arquitectura ResNet50 pre-entrenada con ImageNet. Se utilizaron dos fuentes de datos: el conjunto público AffectNet y un conjunto personalizado recolectado por el equipo mediante un estudio con 30 participantes para simular un aula de RV. La metodología incluyó:

- **Preprocesamiento:** Conversión de imágenes a escala de grises para reducir la carga computacional y resaltar formas; y uso de la librería dlib para detectar 68 puntos de referencia faciales y recortar el área del rostro (rostro completo y mitad inferior para simular oclusión).
- **Arquitectura:** Se modificó ResNet50 descongelando los bloques 4 y 5 para un ajuste fino (*fine-tuning*). Se añadieron capas de Dropout (0.5 y 0.6) y regularización L2 para controlar el sobreajuste (*overfitting*).
- **Entrenamiento:** Se utilizaron técnicas de aumento de datos (giros y rotaciones aleatorias), el optimizador Adam y una programación de la tasa de aprendizaje (*ReduceLROnPlateau*).

I-H. Principales resultados

- **Superioridad de ResNet50:** En comparaciones iniciales, ResNet50 demostró un rendimiento superior en precisión y generalización frente a VGG19 y MobileNet para la detección de emociones en RV.
- **Eficacia del Modelo Personalizado:** El modelo ajustado superó sistemáticamente al ResNet50 predeterminado en todos los experimentos, mostrando una mayor robustez ante datos nuevos y ocluidos.
- **Detección de Aburrimiento:** Se logró diferenciar exitosamente el aburrimiento de la neutralidad (una tarea compleja por su similitud visual), obteniendo resultados razonables incluso con la cara parcialmente cubierta.
- **Eficiencia Técnica:** Se confirmó que el preprocesamiento en escala de grises optimiza el entrenamiento al reducir canales de datos sin perder características esenciales de las expresiones.

I-I. Crítica de la tesis

II. TESIS 2

II-A. Título

Adaptive Intelligent User Interfaces With Emotion Recognition (Interfaces de Usuario Inteligentes y Adaptativas con Reconocimiento de Emociones).

II-B. Autor

Fatma Nasoz. Disertación doctoral presentada en la School of Computer Science, College of Engineering and Computer Science, University of Central Florida, Orlando, Florida. Verano 2004. Directora de tesis: Dr. Christine L. Lisetti.

II-C. Resumen

“El enfoque de esta disertación es la creación de Interfaces de Usuario Inteligentes y Adaptativas para facilitar una comunicación natural y enriquecida durante la Interacción Humano-Computadora, reconociendo los estados afectivos de los usuarios (es decir, las emociones experimentadas por ellos) y respondiendo a esas emociones mediante la adaptación a la situación actual a través de un modelo de usuario afectivo creado para cada usuario. Se diseñaron y realizaron experimentos controlados en un entorno de laboratorio y en un entorno de Realidad Virtual para recolectar señales de datos fisiológicos de participantes que experimentaban emociones específicas. Se implementaron algoritmos (k-Vecinos más Cercanos [KNN], Análisis de Función Discriminante [DFA], Retropropagación de Marquardt [MBP] y Retropropagación Resiliente [RBP]) para analizar las señales de datos recolectadas y encontrar patrones fisiológicos únicos de las emociones. Se realizó un Experimento de Elicitación de Emociones con Clips de Películas para elicitación de Tristeza, Enojo, Sorpresa, Miedo, Frustración y Diversión de los participantes. En general, los tres algoritmos KNN, DFA y MBP pudieron reconocer emociones con una precisión del 72.3 %, 75.0 % y 84.1 %, respectivamente. Se realizó un experimento en un Simulador de Conducción para elicitación de emociones relacionadas con la conducción (pánico/miedo, frustración/enojo y aburrimiento/somnolencia). Los algoritmos KNN, MBP y RBP se utilizaron para clasificar las señales fisiológicas por emociones correspondientes. En general, KNN pudo clasificar estas tres emociones con un 66.3 %, MBP con un 76.7 % y RBP con un 91.9 % de precisión. La adaptación de la interfaz se diseñó para proporcionar retroalimentación multimodal a los usuarios sobre su estado afectivo actual y para responder a los estados emocionales negativos de los usuarios con el fin de disminuir los posibles impactos negativos de esas emociones. Se empleó la formalización de Redes de Creencias Bayesianas para desarrollar el Modelo de Usuario que permite al sistema inteligente adaptarse apropiadamente al contexto y situación actuales considerando factores dependientes del usuario, como rasgos de personalidad y preferencias.”

II-D. Problema que busca resolver

La tesis aborda la brecha fundamental que existe en la Interacción Humano-Computadora (HCI): los sistemas informáticos son incapaces de percibir y responder a los estados emocionales de sus usuarios. Los seres humanos son afectados continuamente por sus emociones, las cuales influyen en procesos cognitivos clave como el aprendizaje, la toma de decisiones, la motivación y el desempeño. Sin embargo, las interfaces digitales convencionales ignoran completamente esta dimensión afectiva.

El problema se manifiesta con especial gravedad en tres dominios de aplicación: (1) la **seguridad vial**, donde emociones como el enojo, la frustración y la somnolencia son causas principales de accidentes de tránsito; (2) el **aprendizaje y entrenamiento**, donde la ansiedad y la frustración reducen la capacidad de aprender y la autoeficacia; y (3) la **telemedicina**, donde la ausencia de canales afectivos en la comunicación médico-paciente remota dificulta el diagnóstico y el tratamiento. En todos estos contextos, una interfaz que pueda reconocer las emociones del usuario y adaptarse en consecuencia mejoraría significativamente la experiencia, la seguridad y los resultados.

II-E. Objetivos

Objetivo General: Diseñar y construir un Sistema Inteligente Adaptativo que reconozca los estados afectivos de sus usuarios a partir de señales fisiológicas no invasivas y que, mediante un modelo de usuario, adapte la interfaz de forma personalizada para mejorar la Interacción Humano-Computadora en aplicaciones de seguridad vial, entrenamiento y telemedicina.

Objetivos Específicos:

1. Diseñar experimentos controlados para elicitación de emociones específicas, recolectar señales fisiológicas de los participantes y registrar sus expresiones faciales; incluyendo un experimento en laboratorio con estímulos multimodales y un experimento de simulador de conducción en Realidad Virtual.
2. Analizar las señales fisiológicas medidas implementando algoritmos de aprendizaje automático (KNN, DFA, MBP, RBP) para identificar patrones fisiológicos únicos asociados a cada emoción.
3. Utilizar los patrones identificados para reconocer las emociones del usuario y desarrollar interfaces de usuario afectivas inteligentes que proporcionen retroalimentación apropiada sobre el estado emocional del usuario.
4. Crear modelos de usuario e integrarlos con las interfaces desarrolladas, empleando Redes de Creencias Bayesianas, para adaptar el sistema a la emoción, la personalidad, la edad y el género del usuario en el contexto y la aplicación actuales.

II-F. Hipótesis

La hipótesis no se enuncia de manera explícita en la tesis. Sin embargo, mediante ingeniería inversa a partir de los experimentos realizados, se puede inferir la siguiente hipótesis subyacente: *Las señales fisiológicas del Sistema Nervioso Autónomo (respuesta galvánica de la piel, frecuencia cardíaca y temperatura cutánea), capturadas mediante dispositivos portátiles no invasivos, contienen patrones únicos para cada emoción que pueden ser identificados por algoritmos de aprendizaje automático con suficiente precisión como para alimentar un sistema adaptativo de interfaz de usuario que, al integrar un modelo de usuario basado en Redes de Creencias Bayesianas, sea capaz de elegir respuestas personalizadas apropiadas al estado emocional del usuario.*

Esta hipótesis habría sido refutada si los algoritmos de aprendizaje automático hubieran mostrado precisiones cercanas al azar (es decir, alrededor del 16.7 % para seis clases), o si los patrones fisiológicos encontrados no hubieran sido estadísticamente distinguibles entre emociones. Los resultados confirmaron la hipótesis: el mejor algoritmo (MBP) alcanzó el 84.1 % de precisión en el experimento de laboratorio y RBP alcanzó el 91.9 % en el experimento de conducción, muy por encima del nivel aleatorio.

II-G. Resumen de la metodología empleada

La investigación empleó una metodología experimental en dos fases, apoyada en el sistema MAUI (*Multimodal Affective User Interface*), herramienta de investigación desarrollada en el laboratorio de la directora de tesis.

- **Instrumentación:** Se utilizó la pulsera BodyMedia SenseWear Armband (dispositivo portátil inalámbrico no invasivo) junto con la banda pectoral Polar para recolectar señales fisiológicas: Respuesta Galvánica de la Piel (GSR), Frecuencia Cardíaca, Temperatura, Movimiento y Flujo de Calor.
- **Experimento 1 — Elicitación de emociones con clips de películas:** Se realizó un estudio piloto con 20 participantes para seleccionar los clips más efectivos de la base de datos de Gross y Levenson. Posteriormente se recolectaron datos de participantes expuestos a seis emociones (Tristeza, Enojo, Sorpresa, Miedo, Frustración y Diversión) mediante estímulos multimodales (videos, imágenes, música y problemas matemáticos). Los datos se analizaron con tres algoritmos: KNN, DFA y MBP.
- **Experimento 2 — Simulador de conducción en Realidad Virtual:** Se diseñó un escenario de conducción virtual con eventos de tráfico que inducían tres emociones relacionadas con la conducción: Pánico/Miedo, Frustración/Enojo y Aburrimiento/Somnolencia. Se añadió el algoritmo RBP (Retropropagación Resiliente) como alternativa al MBP, con una arquitectura de red neuronal de 12 nodos de entrada (características extraídas), 17 nodos en la capa oculta y 3 nodos de salida.
- **Modelado de usuario:** Se emplearon Redes de Creencias Bayesianas (BBN) implementadas en Visual C++ usando la API Netica para modelar al usuario. El modelo incluye como nodos: la emoción reconocida, los rasgos de personalidad (Modelo de Cinco Factores: Neuroticismo, Extraversión, Apertura, Amabilidad y Consciencia), la edad, el género, la frecuencia de experimentar la emoción y la acción óptima de la interfaz. El modelo permite que el sistema adapte su respuesta de forma personalizada.

II-H. Principales resultados

- **Experimento 1 (6 emociones, laboratorio):** Los tres algoritmos lograron clasificar exitosamente las emociones a partir de señales fisiológicas. KNN obtuvo 72.3 %, DFA 75.0 % y MBP 84.1 % de precisión global, todos muy por encima del nivel aleatorio (16.7 % para 6 clases).

- **Experimento 2 (3 emociones relacionadas con conducción, Realidad Virtual):** El algoritmo RBP demostró ser el más eficaz, alcanzando 91.9 % de precisión global, superando a MBP (76.7 %) y KNN (66.3 %). Por emoción, RBP clasificó Pánico/Miedo con 89.7 %, Frustración/Enojo con 96.7 % y Aburrimiento/Somnolencia con 88.9 %.
- **Superioridad de RBP:** Para el problema de reconocimiento de emociones relacionadas con la conducción, el algoritmo RBP demostró consistentemente mayor capacidad de generalización que MBP, siendo su adopción una de las contribuciones metodológicas clave de la tesis.
- **Modelo de usuario con BBN:** El sistema demostró su capacidad de seleccionar acciones de interfaz diferenciadas según la combinación de emoción reconocida, personalidad, edad y género. Por ejemplo, ante un conductor enojado mayor de 25 años, mujer y con rasgo de Consciencia alto, la acción óptima elegida fue sugerir una técnica de relajación (74.3 %); mientras que para un conductor enojado menor de 25 años, hombre y con rasgo Neurótico, la acción elegida fue hacer un chiste (58.1 %).
- **Sistema MAUI funcional:** Se implementó y demostró el sistema completo con avatar antropomórfico capaz de espejear las emociones del usuario (felicidad, tristeza, enojo), reconocer al usuario por su cara y adaptar la interfaz a sus preferencias previamente almacenadas.

II-I. Crítica de la tesis

Aspectos positivos:

La tesis presenta una propuesta ambiciosa e integradora que combina de forma coherente múltiples disciplinas: aprendizaje automático, psicología de las emociones, Realidad Virtual y modelado de usuario. El alcance del trabajo es notable: no se limita a reconocer emociones, sino que cierra el ciclo completo hasta la adaptación de la interfaz, lo cual le otorga un valor práctico evidente. El uso de la pulsera BodyMedia SenseWear es un aporte metodológico destacado; según la propia autora, fue el primer grupo de investigación en utilizarla con fines de reconocimiento de emociones. La inclusión de un experimento en Realidad Virtual (simulador de conducción) es también una fortaleza, ya que aporta validez ecológica adicional. La estructura de la tesis es clara y sigue una progresión lógica bien construida.

Aspectos negativos o mejorables:

En primer lugar, la hipótesis nunca se enuncia de forma explícita, lo que dificulta evaluar con precisión qué estaba probando la investigación. Una tesis doctoral debe formular claramente sus afirmaciones verificables. En segundo lugar, los tamaños de muestra son reducidos y no se reportan con detalle suficiente en todas las secciones; esto limita la validez estadística de los resultados y su generalización a poblaciones más amplias.

En tercer lugar, el modelo de usuario con Redes de Creencias Bayesianas se presenta como funcional, pero la autora reconoce que las probabilidades condicionales del modelo no fueron calibradas por expertos en psicología ni en seguridad

vial, sino que se utilizaron valores arbitrarios para demostrar la viabilidad del enfoque. Esto es una limitación importante que no siempre queda clara para el lector no experto.

En cuarto lugar, el Capítulo 6 se denomina “Visualización de los Resultados” (*Visualization of the Results*), lo que resulta confuso: en realidad es una descripción de las capacidades del sistema MAUI con capturas de pantalla, más que una presentación analítica de resultados. Esta denominación no sigue la convención estándar de tesis y puede inducir a error.

Finalmente, la tesis no incluye ninguna discusión sobre las implicaciones éticas del monitoreo continuo de señales fisiológicas y emocionales de los usuarios, aspecto que resulta relevante incluso para un trabajo del año 2004 y que ha adquirido mucha mayor importancia en la actualidad, dado el contexto de vigilancia digital y privacidad de datos. Esta omisión representa una debilidad de contenido que no está justificada por las limitaciones del área de conocimiento de la época.

III. TESIS 3

III-A. Título

Automatic Spanish Text Complexity (Complejidad Automática de Texto en Español). Trabajo Final de Graduación para optar por el grado de Maestría en Computación, Instituto Tecnológico de Costa Rica, 2023.

III-B. Autor

Mario Alberto Romero Sandoval.

III-C. Resumen

La tesis propone una metodología para la detección automática de complejidad de texto en español utilizando modelos de transformers, evaluando el impacto de la calidad y cantidad de datos de entrenamiento, y explorando la aumentación de datos mediante Grandes Modelos de Lenguaje (LLMs) para paliar la escasez de pares etiquetados en español. Se utiliza BETO (implementación española de BERT) como modelo base y se compara contra un clasificador de Bosque Aleatorio con TF-IDF (*RF-TF-IDF*) como línea base. Dos experimentos principales evalúan: (1) el impacto de la fuente de los datos de simplificación (manual, GPT-3, mT5 y Tuner) sobre el rendimiento del clasificador, y (2) el efecto de combinar conjuntos de datos manuales pequeños con datos aumentados de forma artificial. Los resultados muestran que los datos generados manualmente producen clasificadores significativamente superiores ($F1 \approx 0.83$) frente a los generados por LLMs como GPT-3 ($F1 \approx 0.74$), mT5 ($F1 \approx 0.65$) y Tuner ($F1 \approx 0.55$), y que la aumentación de datos solo es beneficiosa cuando el conjunto semilla es muy pequeño (aproximadamente 97 segmentos de texto).

III-D. Problema que busca resolver

El campo de la simplificación automática de texto en español carece de conjuntos de datos etiquetados con pares de segmentos complejos y simples, los cuales son indispensables para entrenar clasificadores modernos de aprendizaje

profundo. La mayoría de los enfoques existentes se centran en inglés u otros idiomas, y no existen modelos especializados para la clasificación de complejidad textual en español. Esta escasez de datos constituye un cuello de botella fundamental para el desarrollo de herramientas que permitan a poblaciones con comprensión lectora limitada (personas con impedimento visual, lectores no especializados) acceder a información financiera o técnica compleja. La pregunta central es si la generación automática de datos de simplificación mediante LLMs puede compensar la falta de datos etiquetados por humanos.

III-E. Objetivos

Objetivo General: Desarrollar y evaluar métodos de detección automática de complejidad de texto en español usando aprendizaje profundo y técnicas de aumentación de datos.

Objetivos Específicos:

1. Construir y/o identificar fuentes de datos para entrenar un modelo de aprendizaje profundo de detección de complejidad textual en español.
2. Medir el impacto del tamaño del conjunto de datos y el uso de segmentos generados automáticamente en el problema de detección de complejidad textual en español.
3. Proponer una metodología de aumentación de datos para un clasificador de segmentos de texto usando LLMs.
4. Evaluar los efectos del ajuste fino (*fine-tuning*) de modelos de clasificación con datos aumentados como forma de mejorar los resultados del aprendizaje por transferencia cuando se usan únicamente conjuntos de datos pequeños.
5. Contrastar los resultados de usar modelos pre-entrenados como BETO/BERT como base para el aprendizaje por transferencia.

III-F. Hipótesis

La tesis enuncia explícitamente dos hipótesis en la Sección 3.3, lo cual es un aspecto metodológico destacable:

Hipótesis 1: *Las capacidades de generación de texto de GPT-3 pueden utilizarse como fuente de texto aumentado para abordar la baja disponibilidad de datos de pares etiquetados de segmentos complejos y simples, proporcionando resultados similares al usarlo para ajustar modelos.*

Esta hipótesis fue **rechazada**: se encontró una diferencia estadística clara entre todas las fuentes de datos (valor- $p > 0,99$), confirmando que los datos manuales producen modelos significativamente superiores a los entrenados con datos generados por LLMs.

Hipótesis 2: *El aprendizaje por transferencia en modelos pre-entrenados, usando datos aumentados, proporcionará mejoras en el rendimiento del modelo (F1-score) en comparación con modelos entrenados con datos pequeños pero generados manualmente.*

Esta hipótesis fue **confirmada parcialmente**: la aumentación de datos beneficia al modelo únicamente cuando el

conjunto semilla es muy pequeño (aproximadamente 97 segmentos). Para conjuntos semilla de tamaño mayor, agregar datos aumentados no tiene efecto estadísticamente significativo o incluso degrada el rendimiento.

III-G. Resumen de la metodología empleada

- **Conjunto de datos semilla:** 5.314 pares de segmentos de texto complejo/simple, extraídos de documentos de educación financiera y etiquetados manualmente por 6 anotadores humanos usando 21 atributos de simplificación. El corpus fue diseñado originalmente para personas con impedimento visual.
- **Conjuntos de datos aumentados:** Se generaron tres versiones alternativas del mismo corpus: (1) **GPT-3**: simplificaciones generadas por ChatGPT de OpenAI sin instrucciones personalizadas; (2) **mT5**: modelo T5 multilingüe pre-entrenado; (3) **Tuner**: sistema de simplificación léxica basado en reglas para lenguas románicas.
- **Modelos evaluados:** BETO (implementación española de BERT) para ajuste fino por transferencia, y RF+TF-IDF como línea base.
- **Experimento 1 (Capítulo 4):** Comparación de las 4 fuentes de datos $\times$ 2 modelos $\times$ 20 tamaños de conjunto $\times$ validación cruzada $K=10$. Total: 1.600 ejecuciones. División 90%/10% entrenamiento/prueba.
- **Experimento 2 (Capítulo 5):** Evaluación del impacto de la aumentación: 10 tamaños de conjunto semilla $\times$ 16 tamaños de datos aumentados $\times$ 3 repeticiones = 480 configuraciones. Validación estadística con ANOVA ($p = 0,05$).

III-H. Principales resultados

- **Superioridad de los datos manuales:** Con BETO, el conjunto manual alcanzó $F1 \approx 0.83$, seguido por GPT-3 ($F1 \approx 0.74$), mT5 ($F1 \approx 0.65$) y Tuner ($F1 \approx 0.55$). La diferencia estadística entre todos los pares de fuentes fue confirmada (valor- $p > 0,99$), rechazando la Hipótesis 1.
- **Saturación del modelo:** Todos los modelos alcanzan un punto de saturación alrededor de 2.000 segmentos de entrenamiento. El modelo entrenado con datos manuales continúa mejorando hasta aproximadamente 4.000 segmentos, lo que indica una mayor riqueza estructural y semántica respecto a los datos sintéticos.
- **Aumentación útil solo en conjuntos pequeños:** La aumentación de datos con GPT-3 mejora el rendimiento del clasificador únicamente cuando el conjunto semilla contiene aproximadamente 97 segmentos. Con un conjunto semilla de 97 segmentos y 478 segmentos aumentados, se encontró diferencia estadística significativa ($p = 0,05$). Para conjuntos semilla ≥ 492 segmentos, agregar datos aumentados provoca una degradación del rendimiento.
- **Calidad sobre cantidad:** Los resultados muestran una tendencia clara: cuanto mejor es la fuente de datos de aumentación (Tuner $<$ mT5 $<$ GPT-3 $<$ Manual), mayor es el rendimiento máximo alcanzable. La calidad de la

simplificación importa más que el volumen de datos generados.

III-I. Crítica de la tesis

Aspectos positivos:

El diseño experimental de la tesis es especialmente riguroso: las hipótesis están formuladas explícitamente y de forma verificable, se emplean pruebas estadísticas formales (ANOVA) para validar los resultados, y se utilizan múltiples configuraciones de datos para obtener conclusiones robustas. La innovación de explorar LLMs como fuentes de datos aumentados para NLP en español es relevante y oportuna. El corpus semilla, construido con 21 atributos de simplificación y anotadores humanos especializados, es una contribución metodológica significativa. La elección de BETO como modelo base es bien justificada y la comparación contra RF-TF-IDF como línea base es apropiada.

Aspectos negativos o mejorables:

En primer lugar, el documento está escrito íntegramente en inglés, lo cual es inusual para un trabajo de graduación de una institución costarricense cuya audiencia natural es hispanohablante y cuyo dominio de aplicación es precisamente el español. Esta decisión no se justifica en el texto.

En segundo lugar, el corpus de evaluación proviene exclusivamente de documentos de educación financiera, lo que restringe significativamente la generalización de los resultados a otros dominios como salud, educación o tecnología. No se puede saber si los hallazgos se mantienen para textos de dominios distintos.

En tercer lugar, GPT-3 se utilizó para generar simplificaciones sin ninguna instrucción personalizada ni las 21 reglas de simplificación empleadas por los anotadores humanos. Es posible que resultados más favorables se hubieran obtenido con *prompting* especializado, lo que significa que la hipótesis 1 podría haberse explorado con mayor equidad metodológica.

Finalmente, la tesis no incluye análisis de error cualitativo, matrices de confusión por clase ni ejemplos de segmentos mal clasificados, lo que dificulta entender en qué tipos de textos falla el modelo. Tampoco se valida el sistema con usuarios finales (personas con impedimento visual) para confirmar que el clasificador efectivamente apoya la tarea de simplificación en la práctica.

IV. TESIS 4

IV-A. Título

Diseño e implementación de un método para la ejecución de aplicaciones de computación paralela basadas en MPI en un clúster de Kubernetes (Design and Implementation of a Method for Running MPI-Based Parallel Computing Applications in a Kubernetes Cluster). Trabajo Final de Graduación para optar por el grado de Licenciatura en Ingeniería en Ciencias de la Computación e Informática, Universidad de Costa Rica, 2024.

IV-B. Autor

Cristian Arias Chaves.

IV-C. Resumen

La tesis diseña, implementa y valida un método para ejecutar aplicaciones de computación paralela basadas en MPI (*Message Passing Interface*) dentro de un clúster de Kubernetes. El método resuelve los requisitos técnicos de MPI en un entorno contenedorizado (IPs y DNS estables, almacenamiento compartido, ambiente de ejecución uniforme) mediante una combinación de recursos nativos de Kubernetes: *StatefulSets*, servicios *headless*, volúmenes persistentes con BeeGFS e imágenes de contenedor auto-contenidas. El método es automatizado mediante un Operador de Kubernetes desarrollado en Go usando el *Operator SDK*, con dos Definiciones de Recursos Personalizados (CRDs): *MpiCluster* y *MpiJob*. La validación se realiza mediante cuatro experimentos: prueba funcional básica (“Hola Mundo” de MPI), medición del tiempo de creación del clúster, medición del rendimiento de entrada/salida de red y disco, y evaluación del rendimiento de ejecución de aplicaciones con los *benchmarks* MiniFE, MiniMD y MiniXyce de la suite Mantevo. Los tres tipos de imágenes de contenedor probadas (MPICH, OpenMPI y MPICH+SLURM) demuestran que el clúster de trabajo en Kubernetes puede crearse en aproximadamente 21 segundos por nodo, con rendimientos de E/S y de ejecución de aplicaciones superiores al 70 % del rendimiento de un clúster físico equivalente en todos los casos.

IV-D. Problema que busca resolver

Los clústeres HPC (*High Performance Computing*) tradicionales son infraestructura cara, rígida y especializada que requiere inversión de capital significativa y personal técnico dedicado. Kubernetes se ha convertido en el estándar de orquestación de contenedores en la nube, pero no fue diseñado para los requisitos específicos de la computación paralela con MPI: los *deployments* de Kubernetes no garantizan IPs ni DNS estables entre nodos (requisito de MPI para el intercambio de mensajes), no proveen almacenamiento compartido de forma nativa, y la configuración del ambiente de ejecución para cada aplicación paralela debe realizarse manualmente. No existe un método estandarizado, reproducible y productivo para desplegar y gestionar trabajos MPI en Kubernetes, lo que crea una barrera entre el ecosistema moderno de la nube y la comunidad de computación de alto rendimiento.

IV-E. Objetivos

Objetivo General: Diseñar e implementar un método que permita la ejecución de aplicaciones de computación paralela basadas en MPI en un clúster de Kubernetes, con un rendimiento de E/S y de ejecución de aplicaciones no inferior al 70 % respecto a un clúster físico equivalente, y con un tiempo de creación e inicialización de cada nodo del clúster de trabajo no superior a 1 minuto.

Objetivos Específicos:

1. Identificar los requisitos técnicos para la correcta ejecución de aplicaciones MPI en un sistema distribuido y determinar los recursos de Kubernetes más adecuados para satisfacerlos.

2. Diseñar e implementar el método propuesto usando recursos nativos de Kubernetes (*StatefulSet*, servicio *headless*, volumen persistente, *namespace*, cuotas de recursos) e imágenes de contenedor auto-contenidas.
3. Validar el método en un ambiente de desarrollo demostrando la ejecución exitosa de la implementación de Hola Mundo de MPI en todos los nodos del clúster de trabajo.
4. Medir el tiempo de creación del clúster de trabajo y verificar que no supere 1 minuto por nodo ni $1 \times N$ minutos para N nodos.
5. Evaluar el rendimiento de E/S de disco y red del clúster de trabajo en comparación con un clúster físico de Vultr y verificar que supera el 70 %.
6. Evaluar el rendimiento de la ejecución de aplicaciones de computación paralela mediante *benchmarks* de la suite Mantevo y verificar que supera el 70 % del clúster físico.

IV-F. Hipótesis

La tesis formula explícitamente tres hipótesis cuantitativas en el Capítulo 1, lo que permite una evaluación objetiva de los resultados:

1. *El tiempo de creación e inicialización de cada nodo del clúster de trabajo no superará 1 minuto (60 segundos), y el tiempo total para iniciar la ejecución de una aplicación de computación paralela será igual o menor a $1 \times N$ minutos, donde N es el número de nodos del clúster de trabajo.* **Confirmada:** el tiempo promedio fue de aproximadamente 21 segundos por nodo para las tres imágenes evaluadas.
2. *El rendimiento de entrada/salida de disco y red en los nodos del clúster de trabajo de Kubernetes superará el 70 % del rendimiento alcanzado en los nodos del clúster físico de Vultr.* **Confirmada:** el rendimiento de disco fue siempre superior al 70 % (la mayoría de nodos superó el 90 %) y el rendimiento de red superó incluso el 100 % del clúster físico en todos los nodos.
3. *El rendimiento de ejecución de aplicaciones de computación paralela basadas en MPI en el clúster de trabajo de Kubernetes superará el 70 % del rendimiento alcanzado en el clúster físico de Vultr.* **Confirmada:** todos los benchmarks alcanzaron rendimientos promedios superiores al 84 % en escalamiento fuerte y al 91 % en escalamiento débil.

Las tres hipótesis habrían sido refutadas si los tiempos de creación hubieran superado 60 segundos, si el rendimiento de E/S o de ejecución hubiera caído por debajo del 70 %, o si el sistema hubiera fallado en ejecutar correctamente las aplicaciones MPI.

IV-G. Resumen de la metodología empleada

- **Diseño del método:** Se utilizan *StatefulSets* (en lugar de *Deployments*) combinados con un servicio *headless* para garantizar DNS e IPs estables a cada nodo. El almacenamiento compartido se implementa con BeeGFS

(sistema de archivos paralelo de alto rendimiento) montado como volumen persistente. Los recursos se aíslan en un *namespace* con cuotas. Cada nodo ejecuta una imagen de contenedor auto-contenida que incluye el sistema operativo, servidor SSH, y las librerías de MPI requeridas.

- **Implementación del Operador:** Se desarrolló un Operador de Kubernetes en Go usando el *Operator SDK*, con dos CRDs: *MpiCluster* (define el clúster de trabajo: número de nodos, imagen, almacenamiento, recursos) y *MpiJob* (define un trabajo a ejecutar: nombre del trabajo, clúster destino, comando MPI). El operador gestiona todo el ciclo de vida del clúster automáticamente.
- **Imágenes de contenedor evaluadas:** MPICH base, OpenMPI base, y MPICH+SLURM (gestor de colas de trabajos).
- **Infraestructura:** Clúster de Kubernetes en Vultr (proveedor de nube), con 8 *worker nodes* de 15 núcleos y 30 GB RAM cada uno. Clúster de referencia: los mismos *worker nodes* de Vultr sin Kubernetes.
- **Experimentos:**
 1. *Validación funcional:* clúster local con kind (3 nodos), ejecución de MPI Hola Mundo.
 2. *Tiempo de creación:* 3 repeticiones por imagen, 8 nodos, medición en segundos.
 3. *E/S disco:* herramienta DD de Ubuntu, archivo de 500 MB, velocidad en MB/s, 3 repeticiones.
 4. *E/S red:* herramienta iperf, velocidad en Gbps durante 5 segundos, 3 repeticiones.
 5. *Rendimiento de aplicaciones:* suite Mantevo (MiniFE, MiniMD, MiniXyce), escalamiento fuerte (tamaño fijo, más *ranks*) y débil (tamaño proporcional, más *ranks*), de 1 a 120 *ranks* (8 nodos $\times$ 15 núcleos).

IV-H. Principales resultados

- **Tiempo de creación:** Las tres imágenes lograron tiempos promedio de ≈ 21 segundos por nodo (MPICH: 21.58s, OpenMPI: 21.13s, SLURM: 21.13s), muy por debajo del límite de 60 segundos. El primer nodo tardó más (≈ 26 – 29 s) por ser el encargado de generar las claves SSH del clúster.
- **E/S de disco:** El rendimiento del clúster de trabajo frente al clúster de Vultr fue superior al 70 % en todos los nodos; la mayoría superó el 90 %. El coeficiente de variación máximo fue del 10.35 %, indicando datos homogéneos.
- **E/S de red:** El clúster de trabajo superó el rendimiento del clúster de Vultr en todos los nodos (rendimiento entre 102 % y 135 %), posiblemente porque las pruebas se realizaron en horas distintas cuando la red del proveedor estaba saturada, o porque el CNI Calico en modo *Cross-subnet* transmite paquetes de forma más eficiente.
- **MiniFE (escalamiento fuerte):** Rendimiento promedio del clúster de Kubernetes: 97.48 % (mínimo 86 %). Las

curvas de *speedup* de ambos entornos son prácticamente idénticas, especialmente a 2, 4 y 8 nodos.

- **MiniFE (escalamiento débil):** Rendimiento promedio: 91.01 % (mínimo 76 %).
- **MiniMD (escalamiento fuerte):** Rendimiento promedio: 84.76 % (mínimo 65.3 %, valor atípico con 45 *ranks*). Este fue el único resultado inferior al 70 % en todo el estudio, registrado en una sola configuración.
- **MiniMD (escalamiento débil):** Rendimiento promedio: 97.58 % (mínimo 78.96 %). Las curvas de eficiencia de ambos entornos son prácticamente idénticas con 6, 7 y 8 nodos.

IV-I. Crítica de la tesis

Aspectos positivos:

La tesis es un trabajo de ingeniería altamente práctico, bien ejecutado y con una contribución concreta y funcional: el operador de Kubernetes desarrollado está disponible públicamente en GitHub, lo que permite que otros investigadores e ingenieros puedan replicar y extender el trabajo. Las hipótesis son cuantitativas y verificables desde el inicio, y los experimentos están cuidadosamente diseñados con múltiples repeticiones, cálculo de desviaciones estándar y coeficientes de variación que demuestran la robustez de los resultados. La elección de BeeGFS como solución de almacenamiento compartido de alta velocidad está bien justificada frente a NFS (descartado por problemas de rendimiento en HPC). El ciclo completo de diseño, implementación, validación y benchmarking comparativo es coherente y bien documentado.

Aspectos negativos o mejorables:

En primer lugar, la comparación se realiza únicamente contra el mismo proveedor de nube (Vultr) sin Kubernetes, y no contra implementaciones alternativas como Slurm en hardware dedicado, *Kubeflow MPI Operator* u otras soluciones ya existentes para MPI en Kubernetes. Esto limita el posicionamiento del trabajo en el estado del arte y no permite saber si el método propuesto es competitivo frente a enfoques previos.

En segundo lugar, el resultado atípico de MiniMD con 45 *ranks* (65.3 %, único valor por debajo del 70 %) no se investiga en profundidad. La tesis lo reconoce como anómalo pero no ofrece una explicación técnica satisfactoria, lo que deja una duda sobre la robustez del método ante ciertas configuraciones de nodos.

En tercer lugar, la tesis no analiza el *overhead* de recursos del plano de control de Kubernetes (CPU y memoria del *control plane*) ni los límites de escalabilidad del operador. Esto es relevante para aplicaciones en producción con clústeres de decenas o cientos de nodos.

En cuarto lugar, el umbral del 70 % como criterio de éxito no está justificado con referencias a estándares del área de HPC en la nube. Sin esa referencia, es difícil saber si el umbral es exigente, conservador o arbitrario. Finalmente, el operador no implementa características críticas para entornos de producción como tolerancia a fallos, recuperación ante caídas de nodos ni reprogramación automática de trabajos, lo que limita su aplicabilidad más allá del contexto de investigación.

DECLARACIÓN DE TRANSPARENCIA Y USO ÉTICO DE IA

Para la realización de este documento, se utilizaron las herramientas de IA Perplexity, NotebookLM y Claude como un medio auxiliar para apoyar y acelerar el desarrollo del mismo, siguiendo los lineamientos éticos de la Unidad de Posgrado del TEC. Específicamente, Perplexity y NotebookLM se emplearon para la síntesis de información disponible, y Claude se utilizó para el formato, revisión sintáctica, ortográfica y de redacción de este documento.