

Introducción a la Investigación

Tarea 2: Tesis de Maestría

Emmanuel Barrantes Vargas
Isaac Francisco Moreno Fuentes

Tecnológico de Costa Rica
Maestría en Ciencias de la Computación

I. Tesis 1

I-A. Título

Exploring Emotion Recognition of Students in Virtual Reality Classrooms Through Convolutional Neural Networks and Transfer Learning Techniques (Explorando el reconocimiento de emociones de los estudiantes en aulas de realidad virtual a través de redes neuronales convolucionales y técnicas de aprendizaje por transferencia) [1].

I-B. Autor

Michael Shomoye, University of Calgary.

I-C. Resumen

“En los entornos educativos contemporáneos, comprender y evaluar el compromiso de los estudiantes a través de señales no verbales, especialmente las expresiones faciales, es fundamental. Tales señales han informado durante mucho tiempo a los educadores sobre los estados cognitivos y emocionales de los estudiantes, ayudándoles a adaptar sus métodos de enseñanza. Sin embargo, el auge de las plataformas de aprendizaje en línea y las tecnologías avanzadas como la Realidad Virtual (RV) desafían los modos convencionales de medir el compromiso de los estudiantes, especialmente cuando ciertas características faciales se oscurecen o están completamente ausentes. Este trabajo explora el potencial de las Redes Neuronales Convolucionales (CNN), específicamente un modelo de enfoque de entrenamiento personalizado adaptado de la arquitectura ResNet50, para reconocer y distinguir expresiones faciales sutiles en tiempo real, como la neutralidad, el aburrimiento, la felicidad y la confusión. La novedad del enfoque es doble: primero, se optimiza el poder de las CNN para analizar las expresiones faciales en plataformas de aprendizaje digital. Segundo, se innova para el contexto de la RV centrándose en la mitad inferior del rostro para abordar los desafíos de oclusión que plantea el uso de visores de RV. A través de una experimentación exhaustiva, se compara el rendimiento del modelo con la red neuronal residual 50 predeterminada (ResNet50) y se evalúa frente a conjuntos de datos de rostro completo y de rostro ocluido por RV. En última instancia, este esfuerzo tiene como objetivo proporcionar a los educadores una herramienta sofisticada para la evaluación en tiempo

real del compromiso de los estudiantes en entornos de aprendizaje tecnológicamente avanzados, enriqueciendo la experiencia de enseñanza y aprendizaje.” [1]

I-D. Problema que busca resolver

La tesis busca resolver la dificultad que enfrentan los educadores para evaluar el compromiso y el estado emocional de los estudiantes en entornos de aprendizaje virtuales y de Realidad Virtual. En un aula física, los profesores dependen de señales no verbales y expresiones faciales para ajustar su enseñanza, pero en entornos de RV, los visores ocultan la parte superior del rostro (oclusión), eliminando pistas visuales críticas y creando una desconexión entre la instrucción y las necesidades del estudiante [1].

I-E. Objetivos

Objetivo General (inferido): Desarrollar un modelo de reconocimiento de emociones técnicamente robusto, pedagógicamente valioso y éticamente responsable que permita a los educadores obtener información sobre el compromiso de los estudiantes en tiempo real dentro de aulas de Realidad Virtual (RV) [1].

Objetivos Específicos (inferidos):

1. Comparar el rendimiento de la arquitectura ResNet50 con otros modelos de CNN prominentes como VGG19 y MobileNet en el contexto específico de reconocimiento facial en aulas de RV [1].
2. Evaluar la eficacia de un modelo personalizado basado en ResNet50 para diferenciar expresiones sutiles como neutralidad, aburrimiento, felicidad y confusión [1].
3. Determinar las técnicas de preprocesamiento óptimas (como el uso de imágenes en escala de grises) para mejorar el reconocimiento de emociones [1].
4. Superar el desafío de la oclusión facial causada por los visores de RV enfocándose en la parte inferior del rostro [1].

I-F. Hipótesis

La hipótesis no se encuentra explícitamente en el texto pero se infiere que un modelo de Red Neuronal Convolucional (basado en ResNet50) que utilice aprendizaje por transferencia y se centre en las características de la

mitad inferior del rostro podría superar las limitaciones de oclusión de los visores de RV y clasificar con precisión estados emocionales clave del estudiante. Los resultados comprobaron esta hipótesis: el modelo personalizado no solo superó a la versión predeterminada de ResNet50 y a otros modelos, sino que también demostró una alta capacidad para distinguir el aburrimiento de la neutralidad tanto en rostros completos como ocluidos [1].

I-G. Resumen de la metodología empleada

La investigación tomó una red neuronal preentrenada (ResNet50) y la adaptó para reconocer emociones faciales en el contexto específico de aulas de Realidad Virtual. Se usaron dos fuentes de imágenes: una base de datos pública de expresiones faciales (AffectNet) y un conjunto propio recolectado con 30 participantes en un entorno simulado. La metodología incluyó [1]:

- Preparación de imágenes: Las fotografías se convirtieron a blanco y negro para simplificar el procesamiento. Luego se usó un programa de detección de puntos faciales para recortar el área del rostro, generando dos versiones de cada imagen: el rostro completo y únicamente la mitad inferior, para simular la obstrucción del visor de Realidad Virtual [1].
- Ajuste de la red neuronal: Se desbloquearon las capas más profundas de la red preentrenada para que pudiera especializarse en reconocer emociones en este contexto. Se incorporaron técnicas para evitar que el modelo simplemente memorizara los ejemplos de entrenamiento en lugar de aprender a generalizar a imágenes nuevas [1].
- Entrenamiento: Para compensar la cantidad limitada de imágenes disponibles, se generaron variaciones artificiales de cada imagen mediante volteos y rotaciones. Además, se usó un algoritmo que ajusta automáticamente la velocidad de aprendizaje de la red según su propio progreso [1].

I-H. Principales resultados

Los principales hallazgos reportados por [1] son:

- Mejor arquitectura base: De los tres tipos de redes neuronales comparados, ResNet50 mostró mayor precisión y mejor capacidad para generalizar a imágenes nuevas que las alternativas evaluadas (VGG19 y MobileNet), en el contexto específico de detectar emociones en entornos de Realidad Virtual [1].
- Mejora con el modelo ajustado: La versión personalizada de la red neuronal, adaptada específicamente para esta tarea, superó de forma consistente a la versión estándar en todos los experimentos, incluyendo casos donde parte del rostro estaba cubierta por el visor de Realidad Virtual [1].
- Distinción entre aburrimiento y neutralidad: El modelo logró diferenciar exitosamente estas dos emociones, que visualmente son muy similares, y mantuvo

resultados aceptables incluso analizando únicamente la parte inferior del rostro [1].

- Ventaja de procesar imágenes en blanco y negro: Convertir las imágenes a escala de grises antes de procesarlas redujo la carga computacional sin que el modelo perdiera capacidad para reconocer expresiones faciales [1].

I-I. Crítica de la tesis

- Aspectos positivos: La documentación alrededor de la metodología es clara y detallada, así como los diferentes experimentos realizados y sus resultados. También hay una clara relación entre las preguntas de investigación y las conclusiones. Finalmente, al ser un trabajo que involucra seres humanos, se destaca la consideración ética y el consentimiento informado.
- Aspectos por mejorar: En primer lugar, los objetivos y la hipótesis no se enuncian explícitamente, lo que dificulta su identificación. En segundo lugar, la sección de conceptos introductorios es extensa y demasiado general. Por último, la discusión de las limitaciones del estudio es breve y no se observa mucha reflexión crítica sobre los posibles sesgos o limitaciones metodológicas.

II. Tesis 2

II-A. Título

Adaptive Intelligent User Interfaces With Emotion Recognition (Interfaces de Usuario Inteligentes y Adaptativas con Reconocimiento de Emociones) [2].

II-B. Autor

Fatma Nasoz, University of Central Florida.

II-C. Resumen

“El enfoque de esta disertación es la creación de Interfaces de Usuario Inteligentes y Adaptativas para facilitar una comunicación natural y enriquecida durante la Interacción Humano-Computadora, reconociendo los estados afectivos de los usuarios (es decir, las emociones experimentadas por ellos) y respondiendo a esas emociones mediante la adaptación a la situación actual a través de un modelo de usuario afectivo creado para cada usuario. Se diseñaron y realizaron experimentos controlados en un entorno de laboratorio y en un entorno de Realidad Virtual para recolectar señales de datos fisiológicos de participantes que experimentaban emociones específicas. Se implementaron algoritmos (k-Vecinos más Cercanos [KNN], Análisis de Función Discriminante [DFA], Retropropagación de Marquardt [MBP] y Retropropagación Resiliente [RBP]) para analizar las señales de datos recolectadas y encontrar patrones fisiológicos únicos de las emociones. Se realizó un Experimento de Elicitación de Emociones con Clips de Películas para elicitación Tristeza, Enojo, Sorpresa, Miedo, Frustración y Diversión de los participantes. En general, los tres algoritmos KNN, DFA

y MBP pudieron reconocer emociones con una precisión del 72.3 %, 75.0 % y 84.1 %, respectivamente. Se realizó un experimento en un Simulador de Conducción para elicitare emociones relacionadas con la conducción (pánico/miedo, frustración/enojo y aburrimiento/somnolencia). Los algoritmos KNN, MBP y RBP se utilizaron para clasificar las señales fisiológicas por emociones correspondientes. En general, KNN pudo clasificar estas tres emociones con un 66.3 %, MBP con un 76.7 % y RBP con un 91.9 % de precisión. La adaptación de la interfaz se diseñó para proporcionar retroalimentación multimodal a los usuarios sobre su estado afectivo actual y para responder a los estados emocionales negativos de los usuarios con el fin de disminuir los posibles impactos negativos de esas emociones. Se empleó la formalización de Redes de Creencias Bayesianas para desarrollar el Modelo de Usuario que permite al sistema inteligente adaptarse apropiadamente al contexto y situación actuales considerando factores dependientes del usuario, como rasgos de personalidad y preferencias.” [2]

II-D. Problema que busca resolver

La tesis aborda la brecha fundamental que existe en la Interacción Humano-Computadora (HCI): los sistemas informáticos son incapaces de percibir y responder a los estados emocionales de sus usuarios. Los seres humanos son afectados continuamente por sus emociones, las cuales influyen en procesos cognitivos clave como el aprendizaje, la toma de decisiones, la motivación y el desempeño. Sin embargo, las interfaces digitales convencionales ignoran completamente esta dimensión afectiva.

El problema se manifiesta con especial gravedad en tres dominios de aplicación: (1) la seguridad vial, donde emociones como el enojo, la frustración y la somnolencia son causas principales de accidentes de tránsito; (2) el aprendizaje y entrenamiento, donde la ansiedad y la frustración reducen la capacidad de aprender y la autoeficacia; y (3) la telemedicina, donde la ausencia de canales afectivos en la comunicación médico-paciente remota dificulta el diagnóstico y el tratamiento. En todos estos contextos, una interfaz que pueda reconocer las emociones del usuario y adaptarse en consecuencia mejoraría significativamente la experiencia, la seguridad y los resultados.

II-E. Objetivos

Objetivo General: Diseñar y construir un Sistema Inteligente Adaptativo que reconozca los estados afectivos de sus usuarios a partir de señales fisiológicas no invasivas y que, mediante un modelo de usuario, adapte la interfaz de forma personalizada para mejorar la Interacción Humano-Computadora en aplicaciones de seguridad vial, entrenamiento y telemedicina [2].

Objetivos Específicos:

1. Diseñar experimentos controlados para elicitare emociones específicas, recolectar señales fisiológicas de los participantes y registrar sus expresiones faciales;
2. Analizar las señales fisiológicas medidas implementando algoritmos de aprendizaje automático (KNN, DFA, MBP, RBP) para identificar patrones fisiológicos únicos asociados a cada emoción.
3. Utilizar los patrones identificados para reconocer las emociones del usuario y desarrollar interfaces de usuario afectivas inteligentes que proporcionen retroalimentación apropiada sobre el estado emocional del usuario.
4. Crear modelos de usuario e integrarlos con las interfaces desarrolladas, empleando Redes de Creencias Bayesianas, para adaptar el sistema a la emoción, la personalidad, la edad y el género del usuario en el contexto y la aplicación actuales.

II-F. Hipótesis

La hipótesis no se enuncia de manera explícita en la tesis. Sin embargo, mediante ingeniería inversa a partir de los experimentos realizados, se puede inferir la siguiente hipótesis subyacente: Las señales fisiológicas del Sistema Nervioso Autónomo (respuesta galvánica de la piel, frecuencia cardíaca y temperatura cutánea), capturadas mediante dispositivos portátiles no invasivos, contienen patrones únicos para cada emoción que pueden ser identificados por algoritmos de aprendizaje automático con suficiente precisión como para alimentar un sistema adaptativo de interfaz de usuario que, al integrar un modelo de usuario basado en Redes de Creencias Bayesianas, sea capaz de elegir respuestas personalizadas apropiadas al estado emocional del usuario.

Esta hipótesis habría sido refutada si los algoritmos de aprendizaje automático hubieran mostrado precisiones cercanas al azar (es decir, alrededor del 16.7 % para seis clases), o si los patrones fisiológicos encontrados no hubieran sido estadísticamente distinguibles entre emociones. Los resultados confirmaron la hipótesis: el mejor algoritmo (MBP) alcanzó el 84.1 % de precisión en el experimento de laboratorio y RBP alcanzó el 91.9 % en el experimento de conducción, muy por encima del nivel aleatorio [2].

II-G. Resumen de la metodología empleada

La investigación empleó una metodología experimental en dos fases, apoyada en una herramienta propia del laboratorio diseñada para capturar señales corporales y adaptar la interfaz en respuesta a las emociones detectadas [2].

- Instrumentación: Se utilizó una pulsera portátil inalámbrica (BodyMedia SenseWear) junto con un monitor cardíaco pectoral para medir señales del cuerpo: la respuesta eléctrica de la piel (que varía con la activación emocional), la frecuencia cardíaca, la temperatura corporal, el movimiento y el flujo de calor.

- Experimento 1 — Provocación de emociones con clips de películas: Se realizó un estudio previo con 20 participantes para seleccionar los fragmentos de video más efectivos para provocar cada emoción. Luego se recolectaron datos de participantes expuestos a seis emociones (tristeza, enojo, sorpresa, miedo, frustración y diversión) mediante una combinación de videos, imágenes, música y problemas matemáticos. Las señales se analizaron con tres algoritmos de clasificación automática.
- Experimento 2 — Simulador de conducción en Realidad Virtual: Se diseñó un escenario de conducción virtual con eventos de tráfico que inducían tres emociones: pánico o miedo, frustración o enojo, y aburrimiento o somnolencia. Para este experimento se añadió un cuarto algoritmo de clasificación y la red neuronal se configuró con 12 variables de entrada, una capa intermedia de 17 nodos y 3 posibles salidas (una por emoción).
- Modelo de usuario para personalizar la respuesta: Se construyó un modelo probabilístico que toma como entradas la emoción detectada, la edad, el género y cinco rasgos de personalidad del usuario (neuroticismo, extraversión, apertura, amabilidad y responsabilidad), y elige la respuesta más apropiada de la interfaz para esa combinación particular.

II-H. Principales resultados

Los principales hallazgos reportados por [2] son:

- Experimento 1 (6 emociones en laboratorio): Los tres algoritmos de clasificación probados lograron identificar correctamente las emociones a partir de señales corporales. El más básico alcanzó un 72.3 % de precisión, el segundo un 75.0 %, y el más sofisticado un 84.1 %. Para contexto: si el sistema eligiera al azar entre las seis emociones posibles, acertaría solo el 16.7 % de las veces, por lo que estos resultados representan una mejora considerable.
- Experimento 2 (3 emociones en simulador de conducción): En el escenario de conducción virtual, el algoritmo más efectivo alcanzó un 91.9 % de precisión global. Desglosado por emoción, identificó pánico o miedo en el 89.7 % de los casos, frustración o enojo en el 96.7 %, y aburrimiento o somnolencia en el 88.9 %.
- Mejor algoritmo para el contexto de conducción: Uno de los algoritmos de red neuronal evaluados demostró mayor capacidad de adaptarse a datos nuevos que los demás en el escenario de conducción, convirtiéndose en uno de los aportes metodológicos clave de la tesis.
- Adaptación personalizada de la interfaz: El sistema demostró poder elegir respuestas distintas según la combinación de emoción detectada, personalidad, edad y género del usuario. Por ejemplo, ante un conductor enojado mayor de 25 años, mujer y con alto sentido de responsabilidad, el sistema eligió sugerir una técnica de relajación (con 74.3 % de confianza);

para un conductor enojado menor de 25 años, hombre y con tendencia a la ansiedad, la respuesta elegida fue hacer un chiste (con 58.1 % de confianza).

- Sistema completo funcional: Se implementó y demostró el sistema completo, incluyendo un avatar capaz de reflejar las emociones del usuario (felicidad, tristeza, enojo), reconocer al usuario por su cara y adaptar la interfaz a sus preferencias previamente registradas.

II-I. Crítica de la tesis

- Aspectos positivos: Las secciones de la tesis están bien delimitadas y siguen una progresión lógica coherente, desde la fundamentación teórica hasta la validación experimental, lo cual facilita la lectura y comprensión del trabajo. Los objetivos específicos se enuncian de forma explícita y existe una correspondencia clara entre estos y las conclusiones: cada uno es abordado en los experimentos y retomado al cierre del trabajo. El título refleja con precisión el alcance del trabajo, que efectivamente integra el reconocimiento de emociones con la adaptación de interfaces. Asimismo, el alcance es consistente con el trabajo relacionado del área de computación afectiva e HCI, posicionando la propuesta como una contribución integradora frente a trabajos previos que solo abordaban una parte del problema.
- Aspectos de posible mejora: En primer lugar, la hipótesis no se enuncia en ninguna sección de forma explícita, lo que obliga al lector a inferirla mediante ingeniería inversa a partir de los experimentos diseñados. En segundo lugar, aunque los objetivos se alcanzan en términos generales, existe una brecha entre las conclusiones y el objetivo de adaptación: el componente basado en Redes de Creencias Bayesianas fue validado con probabilidades condicionales arbitrarias no calibradas por expertos, lo que debilita el cierre del trabajo respecto a su objetivo más distintivo. En tercer lugar, la sección denominada “Visualización de los Resultados” resulta confusa y mal nombrada: en lugar de presentar resultados analíticos, describe las capacidades visuales del sistema con capturas de pantalla, lo que no sigue la convención estándar de una tesis. Por último, si bien el trabajo relacionado cubre los algoritmos y sensores más relevantes, no justifica explícitamente la elección del enfoque frente a alternativas contemporáneas, dejando el alcance del trabajo parcialmente sin fundamentar en la literatura existente.

III. Tesis 3

III-A. Título

Automatic Spanish Text Complexity Detection in Financial Documents with Low Data Availability (Detección

Automática de Complejidad de Texto en Español en Documentos Financieros con Baja Disponibilidad de Datos) [3].

III-B. Autor

Mario Alberto Romero Sandoval, Instituto Tecnológico de Costa Rica.

III-C. Resumen

“El acceso a la información es un derecho humano fundamental en la sociedad moderna. Sin embargo, no todos tenemos el mismo acceso a la información, y una de las razones es que no comprendemos todo de la misma manera. El nivel educativo, la edad, las discapacidades y el contexto cultural pueden influir en la forma en que un texto es leído y comprendido por el público.

Ser capaz de discriminar entre segmentos de texto complejos y simples tiene numerosas aplicaciones: desde mejorar la eficiencia de los sistemas de simplificación, hasta aplicaciones educativas que ayudan a determinar si un texto es apropiado para el nivel de un estudiante determinado, y también a supervisar si las instituciones se están comunicando correctamente con el público.

En este trabajo se explorarán diferentes métodos y técnicas para la clasificación de textos en función de su complejidad, concretamente texto en español, así como métodos para resolver la escasez de datos en la tarea de discriminación de complejidad de texto en español. En particular, se centrará en el aprovechamiento de modelos de lenguaje existentes y el aprendizaje por transferencia para lograr y medir el impacto de datos aumentados mediante la generación de datos sintéticos en el problema de la discriminación de complejidad de texto.” [3]

III-D. Problema que busca resolver

El campo de la simplificación automática de texto en español carece de conjuntos de datos etiquetados con pares de segmentos complejos y simples, los cuales son indispensables para entrenar clasificadores modernos de aprendizaje profundo. La mayoría de los enfoques existentes se centran en inglés u otros idiomas, y no existen modelos especializados para la clasificación de complejidad textual en español. Esta escasez de datos constituye un cuello de botella fundamental para el desarrollo de herramientas que permitan a poblaciones con comprensión lectora limitada (personas con impedimento visual, lectores no especializados) acceder a información financiera o técnica compleja. La pregunta central es si la generación automática de datos de simplificación mediante LLMs puede compensar la falta de datos etiquetados por humanos.

III-E. Objetivos

Objetivo General: Desarrollar y evaluar métodos de detección automática de complejidad de texto en español usando aprendizaje profundo y técnicas de aumentación de datos [3].

Objetivos Específicos:

1. Construir y/o identificar fuentes de datos para entrenar un modelo de aprendizaje profundo de detección de complejidad textual en español.
2. Medir el impacto del tamaño del conjunto de datos y el uso de segmentos generados automáticamente en el problema de detección de complejidad textual en español.
3. Proponer una metodología de aumentación de datos para un clasificador de segmentos de texto usando LLMs.
4. Evaluar los efectos del ajuste fino (fine-tuning) de modelos de clasificación con datos aumentados como forma de mejorar los resultados del aprendizaje por transferencia cuando se usan únicamente conjuntos de datos pequeños.
5. Contrastar los resultados de usar modelos pre-entrenados como BERT/BETO como base para el aprendizaje por transferencia.

III-F. Hipótesis

La tesis enuncia explícitamente dos hipótesis, lo cual es un aspecto metodológico destacable:

Hipótesis 1: Las capacidades de generación de texto de GPT-3 pueden utilizarse como fuente de texto aumentado para abordar la baja disponibilidad de datos de pares etiquetados de segmentos complejos y simples, proporcionando resultados similares al usarlo para ajustar modelos.

Esta hipótesis fue rechazada: se encontró una diferencia estadística clara entre todas las fuentes de datos (valor- $p > 0,99$), confirmando que los datos manuales producen modelos significativamente superiores a los entrenados con datos generados por LLMs.

Hipótesis 2: El aprendizaje por transferencia en modelos pre-entrenados, usando datos aumentados, proporcionará mejoras en el rendimiento del modelo (F1-score) en comparación con modelos entrenados con datos pequeños pero generados manualmente.

Esta hipótesis fue confirmada parcialmente: la aumentación de datos beneficia al modelo únicamente cuando el conjunto semilla es muy pequeño (aproximadamente 97 segmentos). Para conjuntos semilla de tamaño mayor, agregar datos aumentados no tiene efecto estadísticamente significativo o incluso degrada el rendimiento [3].

III-G. Resumen de la metodología empleada

La metodología empleada por [3] se describe a continuación:

- Datos de partida: Se usaron 5.314 pares de fragmentos de texto, cada par formado por una versión compleja y una simplificada del mismo contenido, extraídos de documentos de educación financiera y etiquetados manualmente por seis personas especializadas. Estos datos habían sido creados originalmente para apoyar a personas con impedimento visual.

- Generación de datos adicionales artificiales: Para estudiar si era posible compensar la escasez de datos reales, se generaron tres conjuntos alternativos de simplificaciones: uno usando ChatGPT sin instrucciones personalizadas, otro usando un modelo de lenguaje multilingüe llamado mT5, y un tercero usando un sistema automático de simplificación basado en reglas lingüísticas para idiomas románicos (Tuner).
- Modelos evaluados: Se compararon dos tipos de clasificadores: BETO, un modelo de inteligencia artificial preentrenado específicamente en texto en español que se ajustó para la tarea de detectar complejidad; y un clasificador más tradicional basado en estadísticas de frecuencia de palabras, usado como punto de referencia base.
- Experimento 1: Se compararon las cuatro fuentes de datos (manual, ChatGPT, mT5 y Tuner) con los dos modelos y veinte tamaños distintos de conjunto de entrenamiento, repitiendo cada combinación diez veces para obtener resultados estables. En total se realizaron 1.600 ejecuciones.
- Experimento 2: Se evaluó específicamente el efecto de agregar datos artificiales a distintos tamaños de datos reales, con 480 combinaciones distintas. Los resultados se validaron con una prueba estadística formal para confirmar que las diferencias observadas no fueran producto del azar.

III-H. Principales resultados

Los principales hallazgos reportados por [3] son:

- Los datos anotados por humanos producen mejores modelos: Usando BETO, un modelo de inteligencia artificial especializado en español, los textos etiquetados manualmente obtuvieron una puntuación de precisión de 0.83 sobre 1. Los textos generados por ChatGPT alcanzaron 0.74, los de otro modelo de lenguaje (mT5) un 0.65, y los de un sistema automático de simplificación basado en reglas (Tuner) un 0.55. Las pruebas estadísticas confirmaron que la diferencia entre todas las fuentes es real y no producto del azar, rechazando así la primera hipótesis de la tesis.
- El modelo deja de mejorar a partir de cierta cantidad de textos: Todos los modelos llegan a un punto a partir del cual agregar más textos de entrenamiento ya no mejora su desempeño, alrededor de los 2.000 textos. El modelo entrenado con datos manuales continuó mejorando hasta los 4.000 textos aproximadamente, lo que indica que los datos humanos contienen información más rica.
- Los datos artificiales solo ayudan cuando se tienen muy pocos datos reales: Agregar textos generados por ChatGPT mejoró el rendimiento del modelo solo cuando el conjunto de datos reales era muy pequeño (alrededor de 97 textos). Con ese punto de partida y casi 500 textos artificiales adicionales, la mejora fue

estadísticamente comprobable. Sin embargo, cuando ya se contaba con más de 492 textos reales, agregar datos artificiales empeoró el rendimiento.

- La calidad de los datos importa más que la cantidad: A mejor fuente de datos, mayor el rendimiento máximo alcanzable, independientemente del volumen generado. Producir más datos de baja calidad no compensa la falta de datos bien anotados por personas.

III-I. Crítica de la tesis

- Aspectos positivos: La estructura de secciones es sólida y sigue una progresión metodológica bien articulada, desde la revisión de literatura hasta la validación experimental con pruebas estadísticas formales. A diferencia de otras tesis del área, las hipótesis se enuncian de forma explícita y verificable, y los objetivos específicos se corresponden directamente con las conclusiones: la Hipótesis 1 fue rechazada estadísticamente y la Hipótesis 2 fue confirmada parcialmente, con resultados cuantitativos claros para cada caso. El título es transparente sobre el alcance del trabajo al declarar desde el inicio las restricciones de dominio (documentos financieros) y de datos (baja disponibilidad), lo que es coherente con el trabajo relacionado que motivó la investigación.
- Aspectos de posible mejora: En primer lugar, los textos usados para evaluar el modelo son únicamente documentos financieros, lo que restringe la generalización de los resultados; el trabajo relacionado abarca dominios más amplios, por lo que el alcance del trabajo no queda totalmente alineado con la literatura que lo precede. En segundo lugar, GPT-3 se empleó sin instrucciones personalizadas ni las 21 reglas de simplificación usadas por los anotadores humanos, lo que hace que el rechazo de la Hipótesis 1 no sea concluyente sobre el potencial real de los LLMs con prompting especializado. Por último, la tesis está escrita íntegramente en inglés para una institución costarricense cuyo dominio de aplicación es el español, sin que esta decisión se justifique en ninguna sección del documento.

IV. Tesis 4

IV-A. Título

Diseño e implementación de un método para la ejecución de aplicaciones de computación paralela basadas en MPI en un clúster de Kubernetes [4].

IV-B. Autor

Cristian Arias Chaves, Universidad de Costa Rica.

IV-C. Resumen

La tesis diseña, implementa y valida un método para ejecutar aplicaciones de computación paralela basadas en MPI (Message Passing Interface) dentro de un clúster de Kubernetes. El método resuelve los requisitos técnicos de

MPI en un entorno contenedorizado (IPs y DNS estables, almacenamiento compartido, ambiente de ejecución uniforme) mediante una combinación de recursos nativos de Kubernetes: StatefulSets, servicios headless, volúmenes persistentes con BeeGFS e imágenes de contenedor auto-contenidas. El método es automatizado mediante un Operador de Kubernetes desarrollado en Go usando el Operator SDK, con dos Definiciones de Recursos Personalizados (CRDs): `MpiCluster` y `MpiJob`. La validación se realiza mediante cuatro experimentos: prueba funcional básica (“Hola Mundo” de MPI), medición del tiempo de creación del clúster, medición del rendimiento de entrada/salida de red y disco, y evaluación del rendimiento de ejecución de aplicaciones con los benchmarks MiniFE, MiniMD y MiniXyce de la suite Mantevo. Los tres tipos de imágenes de contenedor probadas (MPICH, OpenMPI y MPICH+SLURM) demuestran que el clúster de trabajo en Kubernetes puede crearse en aproximadamente 21 segundos por nodo, con rendimientos de E/S y de ejecución de aplicaciones superiores al 70 % del rendimiento de un clúster físico equivalente en todos los casos [4].

IV-D. Problema que busca resolver

Los clústeres HPC (High Performance Computing) tradicionales son infraestructura cara, rígida y especializada que requiere inversión de capital significativa y personal técnico dedicado. Kubernetes se ha convertido en el estándar de orquestación de contenedores en la nube, pero no fue diseñado para los requisitos específicos de la computación paralela con MPI: los deployments de Kubernetes no garantizan IPs ni DNS estables entre nodos (requisito de MPI para el intercambio de mensajes), no proveen almacenamiento compartido de forma nativa, y la configuración del ambiente de ejecución para cada aplicación paralela debe realizarse manualmente. No existe un método estandarizado, reproducible y productivo para desplegar y gestionar trabajos MPI en Kubernetes, lo que crea una barrera entre el ecosistema moderno de la nube y la comunidad de computación de alto rendimiento.

IV-E. Objetivos

Objetivo General: Diseñar e implementar un método que permita la ejecución de aplicaciones de computación paralela basadas en MPI en un clúster de Kubernetes, con un rendimiento de E/S y de ejecución de aplicaciones no inferior al 70 % respecto a un clúster físico equivalente, y con un tiempo de creación e inicialización de cada nodo del clúster de trabajo no superior a 1 minuto [4].

Objetivos Específicos:

1. Identificar los requisitos técnicos para la correcta ejecución de aplicaciones MPI en un sistema distribuido y determinar los recursos de Kubernetes más adecuados para satisfacerlos.
2. Diseñar e implementar el método propuesto usando recursos nativos de Kubernetes (StatefulSet, servicio

headless, volumen persistente, namespace, cuotas de recursos) e imágenes de contenedor auto-contenidas.

3. Validar el método en un ambiente de desarrollo demostrando la ejecución exitosa de la implementación de Hola Mundo de MPI en todos los nodos del clúster de trabajo.
4. Medir el tiempo de creación del clúster de trabajo y verificar que no supere 1 minuto por nodo ni $1 \times N$ minutos para N nodos.
5. Evaluar el rendimiento de E/S de disco y red del clúster de trabajo en comparación con un clúster físico de Vultr y verificar que supera el 70 %.
6. Evaluar el rendimiento de la ejecución de aplicaciones de computación paralela mediante benchmarks de la suite Mantevo y verificar que supera el 70 % del clúster físico.

IV-F. Hipótesis

La tesis formula explícitamente tres hipótesis cuantitativas, lo que permite una evaluación objetiva de los resultados:

1. El tiempo de creación e inicialización de cada nodo del clúster de trabajo no superará 1 minuto (60 segundos), y el tiempo total para iniciar la ejecución de una aplicación de computación paralela será igual o menor a $1 \times N$ minutos, donde N es el número de nodos del clúster de trabajo. Confirmada: el tiempo promedio fue de aproximadamente 21 segundos por nodo para las tres imágenes evaluadas.
2. El rendimiento de entrada/salida de disco y red en los nodos del clúster de trabajo de Kubernetes superará el 70 % del rendimiento alcanzado en los nodos del clúster físico de Vultr. Confirmada: el rendimiento de disco fue siempre superior al 70 % (la mayoría de nodos superó el 90 %) y el rendimiento de red superó incluso el 100 % del clúster físico en todos los nodos.
3. El rendimiento de ejecución de aplicaciones de computación paralela basadas en MPI en el clúster de trabajo de Kubernetes superará el 70 % del rendimiento alcanzado en el clúster físico de Vultr. Confirmada: todos los benchmarks alcanzaron rendimientos promedios superiores al 84 % en escalamiento fuerte y al 91 % en escalamiento débil.

Las tres hipótesis habrían sido refutadas si los tiempos de creación hubieran superado 60 segundos, si el rendimiento de E/S o de ejecución hubiera caído por debajo del 70 %, o si el sistema hubiera fallado en ejecutar correctamente las aplicaciones MPI [4].

IV-G. Resumen de la metodología empleada

La metodología empleada por [4] se describe a continuación:

- **Diseño del método:** Para resolver los requisitos técnicos de la computación paralela dentro de Kubernetes, se usaron recursos especializados de la plataforma que

garantizan que cada servidor tenga una dirección de red estable y un nombre fijo, necesario para que los procesos paralelos puedan comunicarse entre sí. El almacenamiento compartido entre servidores se implementó con un sistema de archivos de alto rendimiento diseñado para computación paralela (BeeGFS). Cada servidor ejecuta un contenedor auto-contenido que incluye el sistema operativo y las librerías necesarias para correr los programas paralelos.

- Automatización mediante un programa gestor: Se desarrolló un programa de automatización que gestiona todo el ciclo de vida del clúster: crearlo, configurarlo y eliminarlo. Este programa permite al usuario definir la configuración del clúster (cantidad de servidores, tipo de software y almacenamiento) y los trabajos a ejecutar, sin necesidad de intervención manual en cada paso.
- Configuraciones de software evaluadas: Se probaron tres variantes de software para ejecutar programas paralelos: dos implementaciones estándar del protocolo de comunicación entre procesos (MPICH y OpenMPI), y una tercera que además incluye un gestor de colas de trabajos para entornos más complejos.
- Infraestructura: El clúster en Kubernetes se montó en la nube sobre ocho servidores de 15 núcleos y 30 GB de memoria RAM cada uno. Como referencia de comparación se usó el mismo proveedor de nube pero con los mismos servidores configurados sin Kubernetes, para simular un clúster físico equivalente.
- Experimentos de validación:
 1. Prueba funcional básica: se verificó que el clúster ejecutara correctamente un programa paralelo sencillo en todos los servidores.
 2. Tiempo de arranque: se midió cuántos segundos tarda en quedar listo cada servidor del clúster.
 3. Velocidad de disco: se midió la velocidad de lectura y escritura de archivos en disco en cada servidor.
 4. Velocidad de red: se midió la velocidad de transferencia de datos entre servidores.
 5. Rendimiento de aplicaciones: se ejecutaron tres programas de simulación científica variando la cantidad de procesos paralelos activos (de 1 a 120), para comparar el rendimiento en Kubernetes contra el del servidor físico de referencia.

IV-H. Principales resultados

Los principales hallazgos reportados por [4] son:

- Tiempo de arranque del clúster: Las tres configuraciones de software probadas lograron tiempos promedio de aproximadamente 21 segundos por servidor, muy por debajo del límite de 60 segundos establecido como criterio de éxito. El primer servidor tardó un poco más (entre 26 y 29 segundos) porque es el encargado de generar las credenciales de seguridad para todos los demás nodos del clúster.
- Velocidad de lectura y escritura en disco: El rendimiento del clúster en Kubernetes superó el 70 % del rendimiento del servidor físico de referencia en todos los nodos; la mayoría alcanzó más del 90 %. Los resultados fueron consistentes entre repeticiones, lo que indica estabilidad del sistema.
- Velocidad de transferencia de datos por red: El clúster en Kubernetes superó al servidor físico de referencia en todos los nodos, con rendimientos de entre el 102 % y el 135 %. Esto se atribuye a que las pruebas del servidor físico posiblemente se realizaron en momentos de mayor congestión de red, o a que el componente de red de Kubernetes transmite datos de forma más eficiente en esa configuración.
- Rendimiento ejecutando simulaciones — MiniFE: Con un programa de simulación de elementos finitos, el clúster en Kubernetes alcanzó un rendimiento promedio del 97.48 % respecto al servidor físico cuando el tamaño del problema era fijo y se aumentaban los procesos paralelos, y del 91.01 % cuando el tamaño del problema crecía junto con los procesos. En ambos casos el comportamiento fue casi idéntico al del servidor físico.
- Rendimiento ejecutando simulaciones — MiniMD: Con un simulador de dinámica molecular, el promedio fue del 84.76 % con problema de tamaño fijo y del 97.58 % con tamaño proporcional. El único resultado por debajo del 70 % en todo el estudio fue un caso aislado con 45 procesos paralelos en esta prueba (65.3 %), que la tesis reconoce como atípico sin ofrecer una explicación técnica definitiva.

IV-I. Crítica de la tesis

- Aspectos positivos: Las secciones siguen una secuencia lógica clara de diseño, implementación y validación, coherente con el tipo de tesis de ingeniería aplicada. Las tres hipótesis son cuantitativas y verificables, se corresponden directamente con los objetivos específicos y las conclusiones las confirman de forma explícita, cerrando el ciclo del trabajo con rigor. El título describe con precisión el alcance del método propuesto y el alcance es consistente con el trabajo relacionado: la tesis posiciona correctamente la brecha entre el HPC tradicional y el ecosistema Kubernetes antes de proponer su solución, lo que justifica la pertinencia del trabajo dentro de la literatura existente.
- Aspectos de posible mejora: En primer lugar, la comparación se realiza únicamente contra el mismo proveedor de nube sin Kubernetes, sin contrastar el método frente a soluciones alternativas existentes como el Kubeflow MPI Operator o Slurm; esto limita el posicionamiento del trabajo en el estado del arte y debilita las conclusiones respecto a su ventaja competitiva. En segundo lugar, el criterio de éxito del 70 % de rendimiento no se fundamenta con referencias

a estándares del área de HPC en la nube, por lo que no queda claro si el umbral es exigente o conservador dentro de la literatura. Por último, el resultado atípico de MiniMD con 45 ranks (65.3 %, único valor inferior al 70 %) no recibe una explicación técnica satisfactoria, lo que genera una duda sobre la robustez del método ante ciertas configuraciones de nodos.

Declaración de Transparencia y Uso Ético de IA

Para la realización de este documento, se utilizaron las herramientas de IA NotebookLM y Claude como un medio auxiliar para apoyar y acelerar el desarrollo del mismo, siguiendo los lineamientos éticos de la Unidad de Posgrado del TEC. Específicamente, NotebookLM se empleó para la síntesis de información disponible, y Claude se utilizó para el formato, revisión sintáctica y ortográfica de este documento.

Referencias

- [1] Michael Abidemi Shomoye. “Exploring Emotion Recognition of Students in Virtual Reality Classrooms Through Convolutional Neural Networks and Transfer Learning Techniques”. Master of Science Thesis. Calgary, Alberta, Canada: University of Calgary, ene. de 2024.
- [2] Fatma Nasoz. “Adaptive Intelligent User Interfaces With Emotion Recognition”. Tesis doct. Orlando, Florida, USA: University of Central Florida, ago. de 2004. url: <https://stars.library.ucf.edu/etd/146>.
- [3] Mario Alberto Romero Sandoval. “Automatic Spanish Text Complexity Detection in Financial Documents with Low Data Availability”. Tesis de Maestría en Computación. San José, Costa Rica: Instituto Tecnológico de Costa Rica, mayo de 2024.
- [4] Cristian Arias Chaves. “Método para la administración de cargas de trabajo de computación paralela en un clúster de Kubernetes”. Tesis de Magíster Scientiae en Computación. San José, Costa Rica: Instituto Tecnológico de Costa Rica, jun. de 2024.